

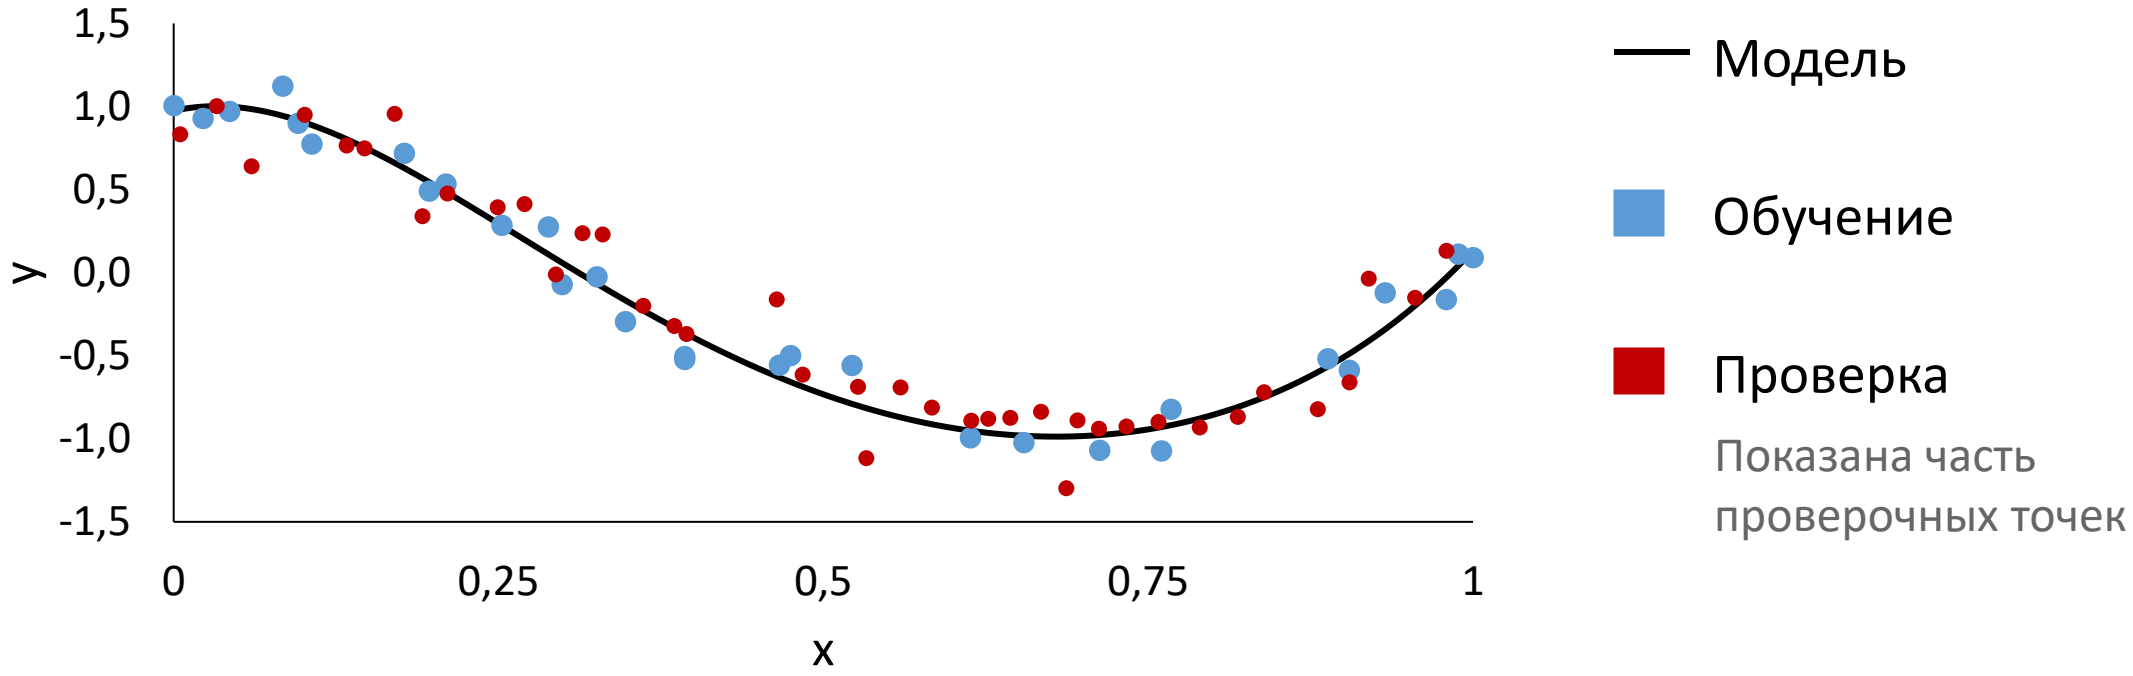


Надежная оценка качества и перекрестная проверка

М.А. Криницкий

ГДЕ ИЗМЕРЕНА ОШИБКА?

Качество — это метрика и данные, на которых она вычислена



$$RMSE = \sqrt{\left[(1/n) \sum (\hat{y}_i - y_i)^2 \right]}$$

СТЕПЕНЬ МЕНЯЕТ ГИБКОСТЬ

Одна зависимость, разные пространства моделей

$$\hat{y}(x) = \sum \theta_j x^j, \quad j = 0, \ldots, d$$

d

Степень полинома

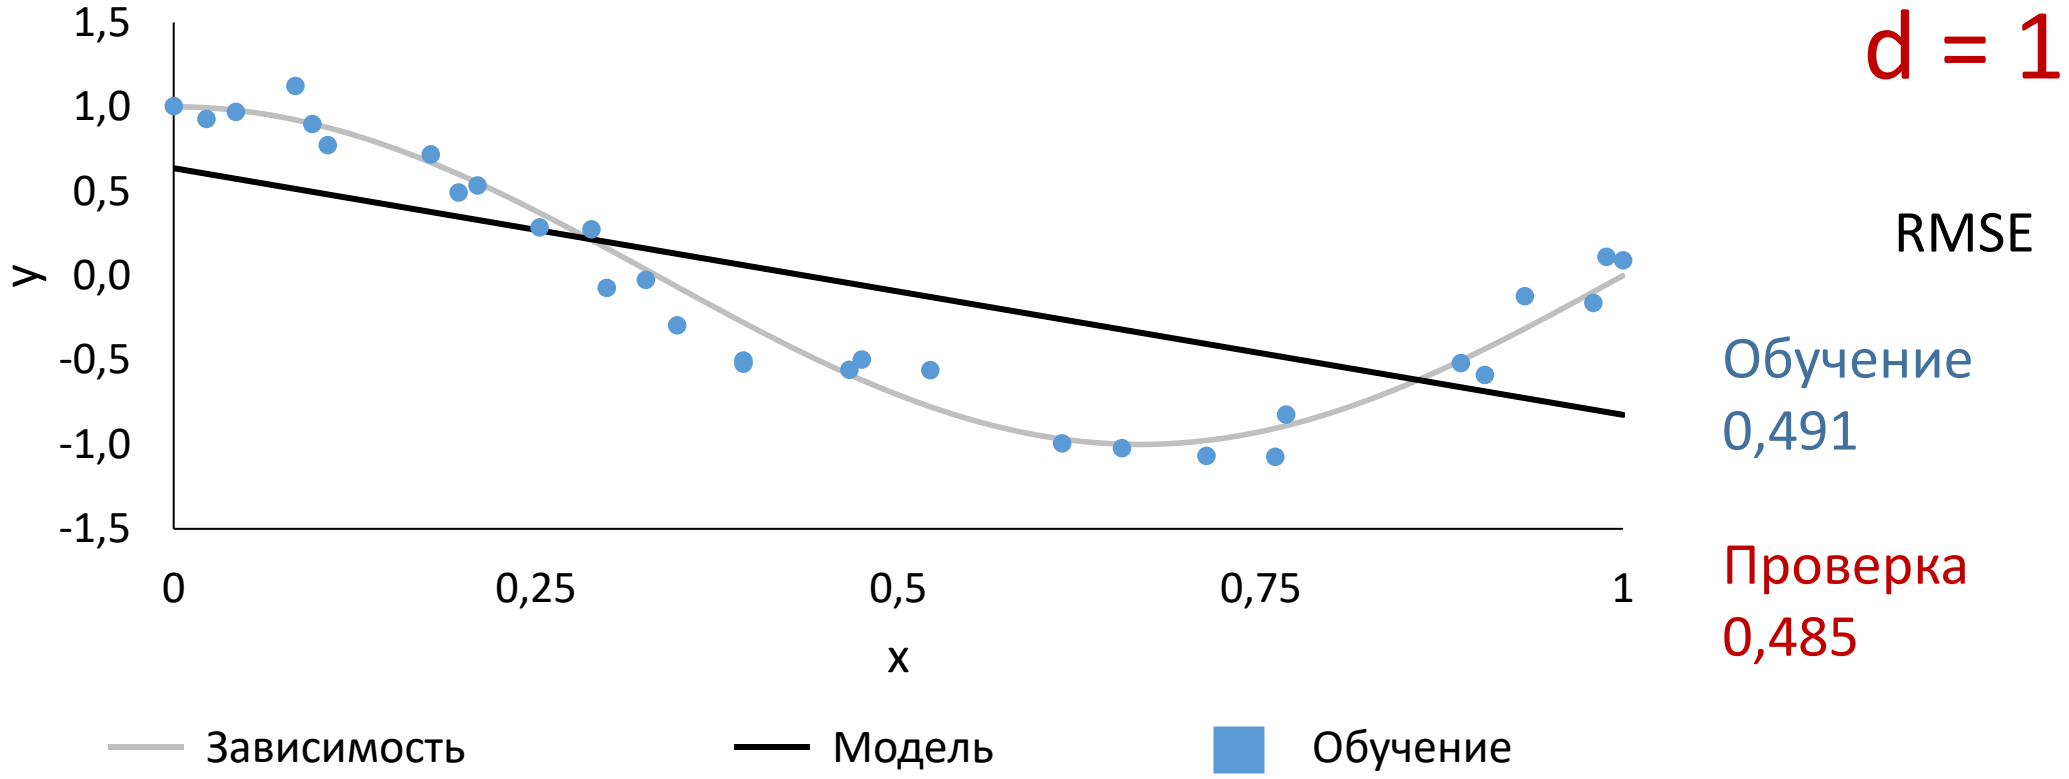
θ

Коэффициенты

Степень выбираем · коэффициенты обучаем

СЛИШКОМ ПРОСТАЯ МОДЕЛЬ

Те же данные и те же оси



d = 1

RMSE

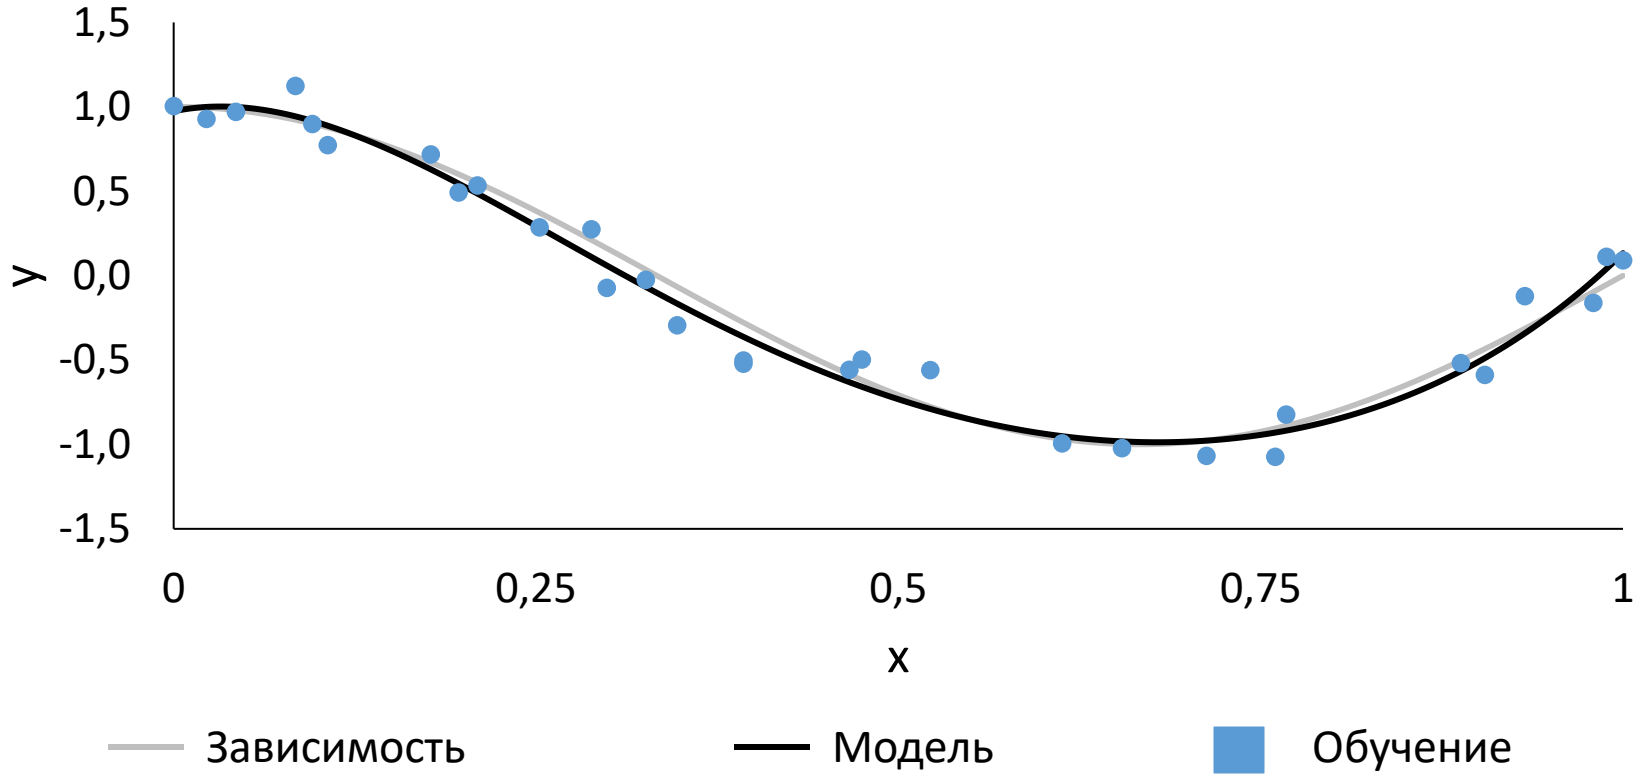
Обучение
0,491

Проверка
0,485

Модель не воспроизводит форму зависимости

ПОДХОДЯЩАЯ СЛОЖНОСТЬ

Те же данные и те же оси



d = 5

RMSE

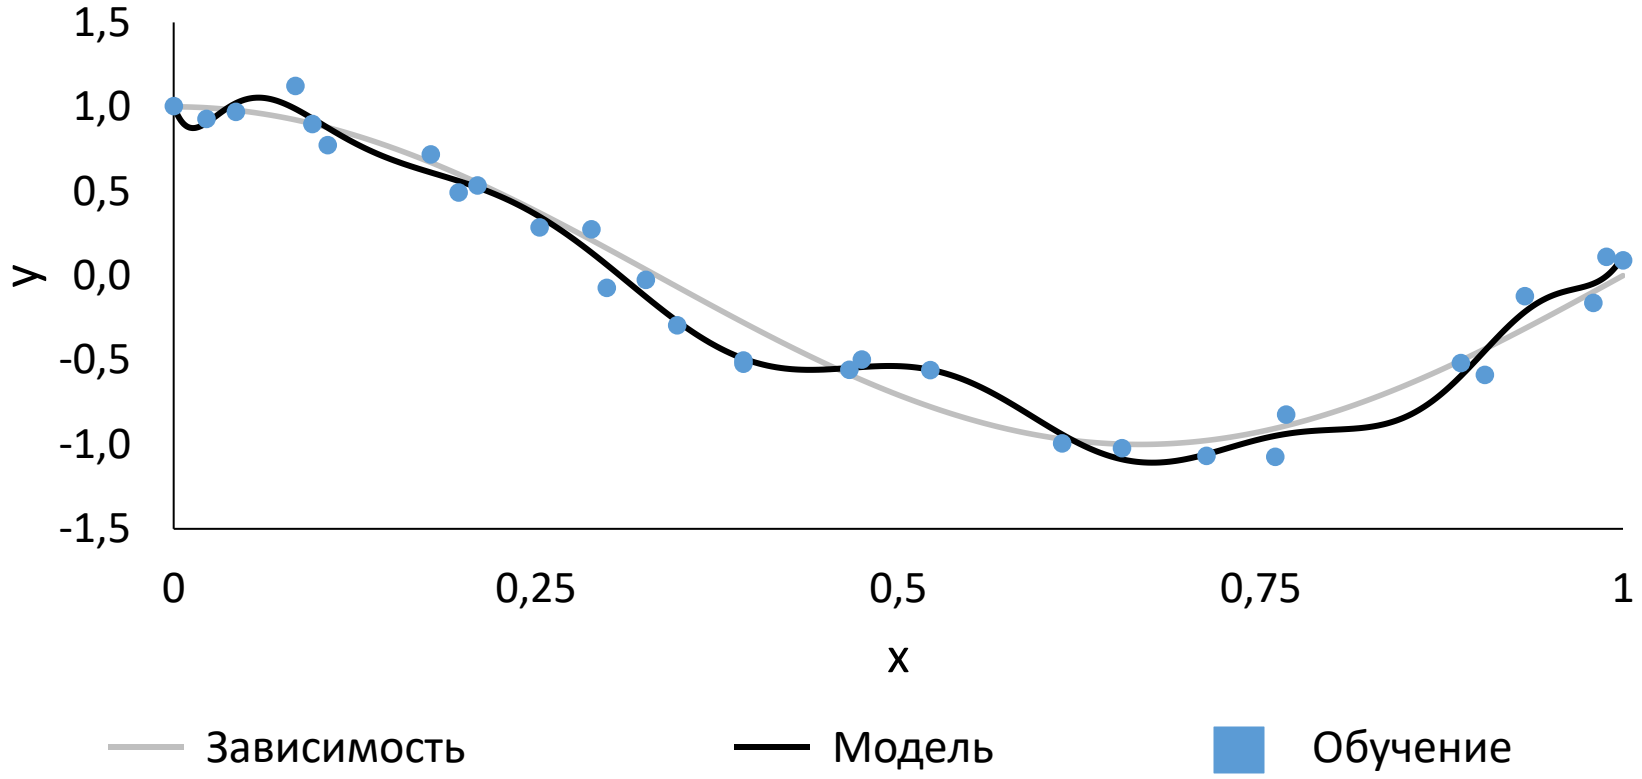
Обучение
0,113

Проверка
0,182

Форма зависимости восстановлена лучше

ПОДГОНКА ШУМА

Те же данные и те же оси



d = 15

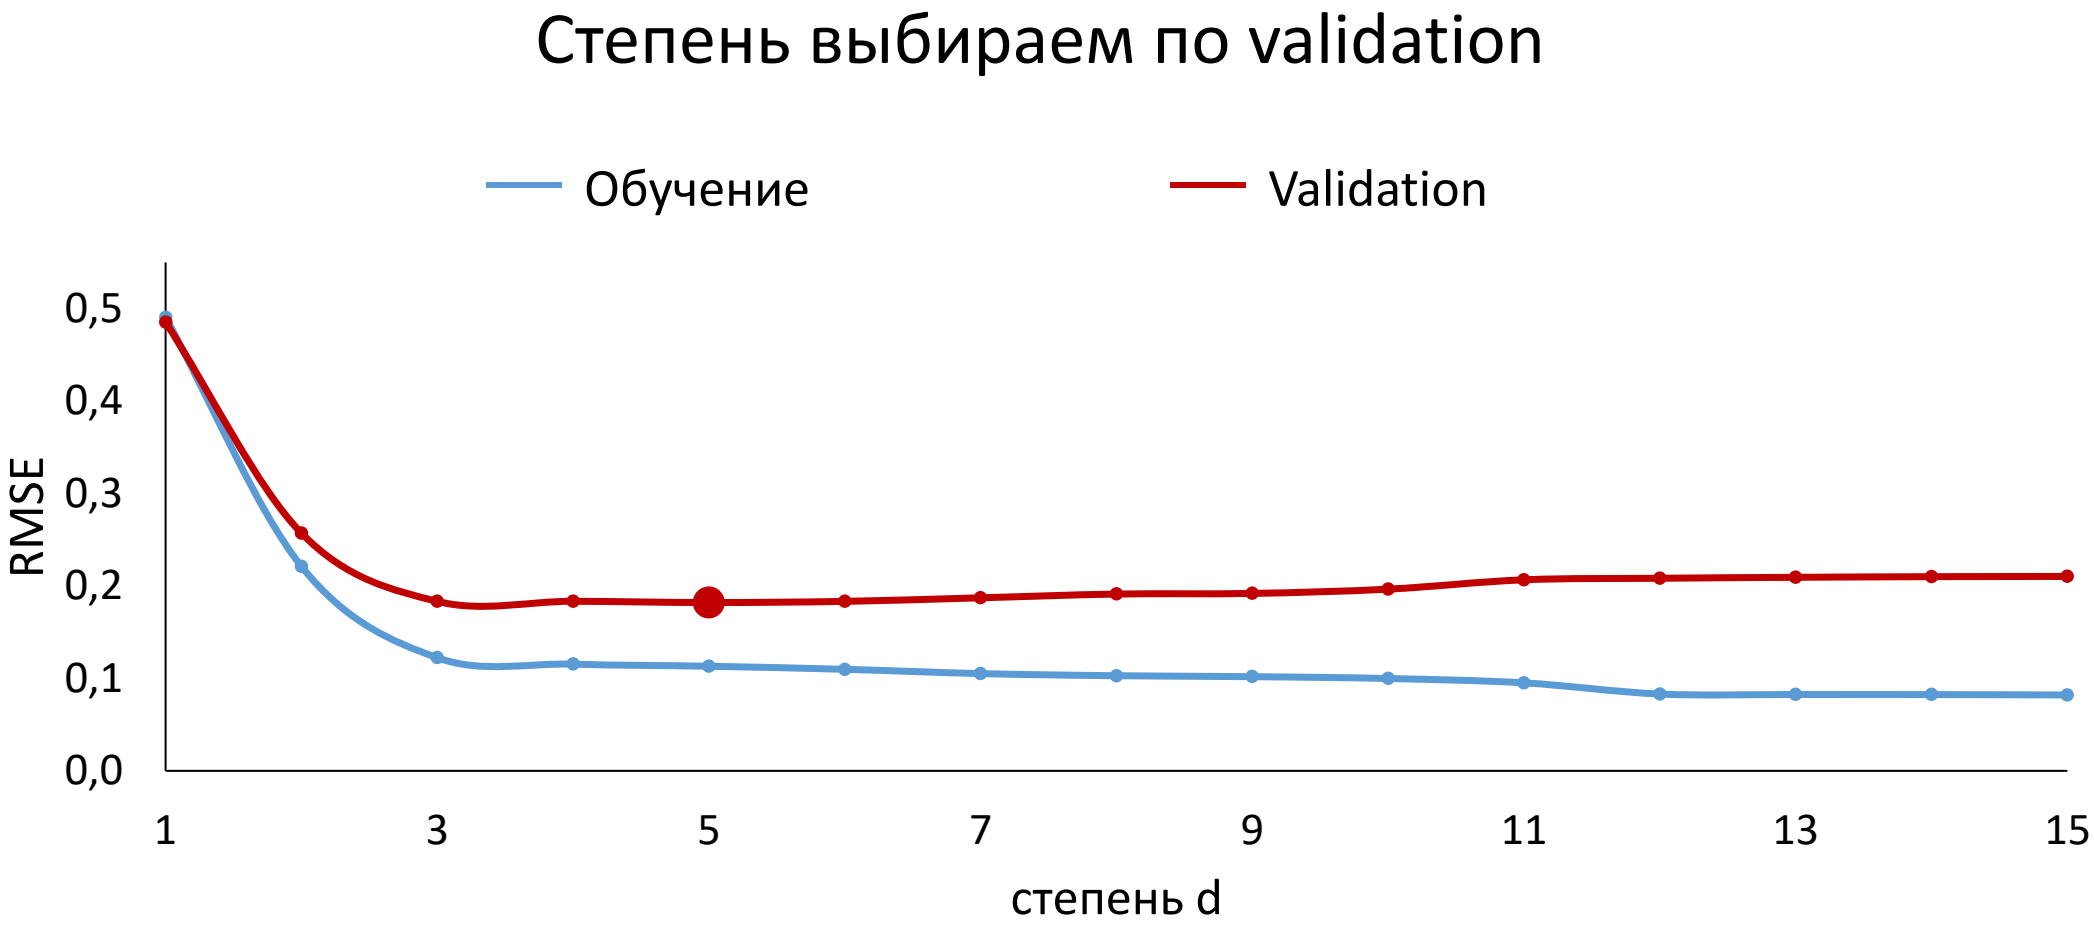
RMSE

Обучение
0,082

Проверка
0,210

Обучение улучшается, проверка ухудшается

ОШИБКА ОБУЧЕНИЯ И ОШИБКА ПРОВЕРКИ



Минимум validation в этом опыте: d = 5

КОЭФФИЦИЕНТЫ И СТЕПЕНЬ

Две задачи — два источника информации

θ

Обучаем коэффициенты

Train

d

Выбираем степень

Validation

Проверочные ответы тоже влияют на выбор модели

ТРИ РОЛИ ДАННЫХ

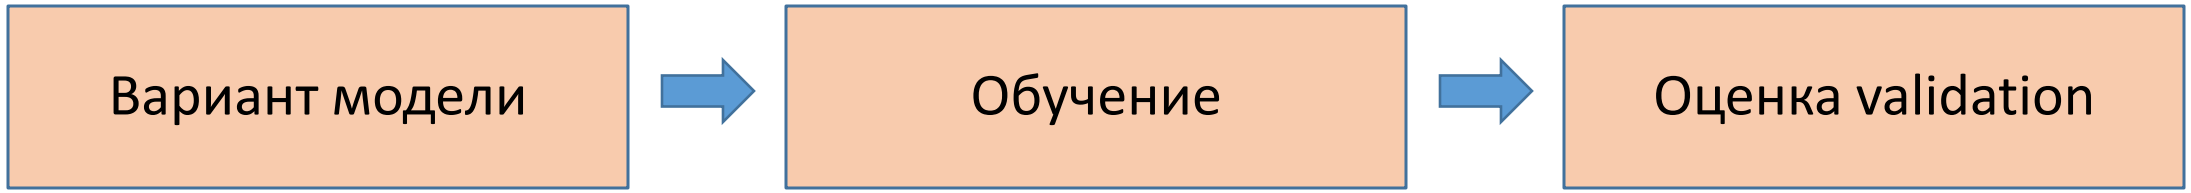
Когда модель и её настройки выбираются по данным

Train	Validation	Test
Обучить параметры	Выбрать вариант	Оценить итоговый результат

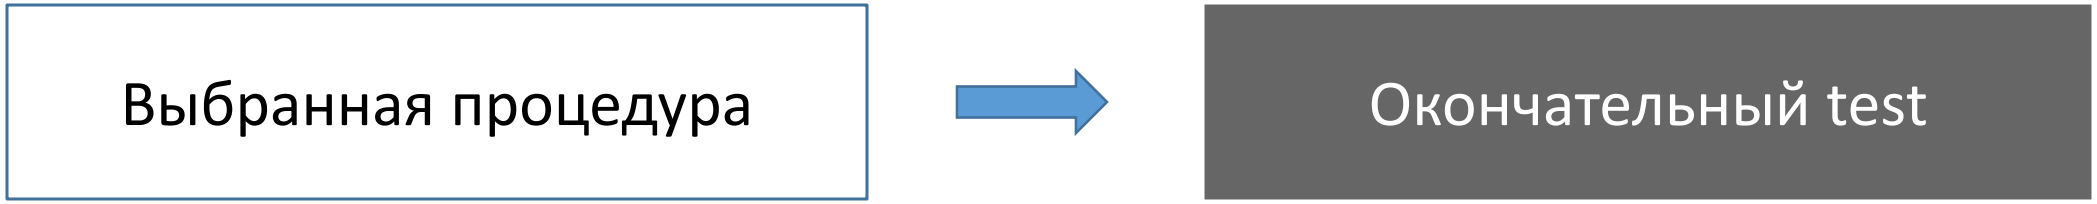
Окончательный test остаётся вне выбора модели

ВЫБРАТЬ, ЗАТЕМ ПРОВЕРИТЬ

Validation участвует в разработке



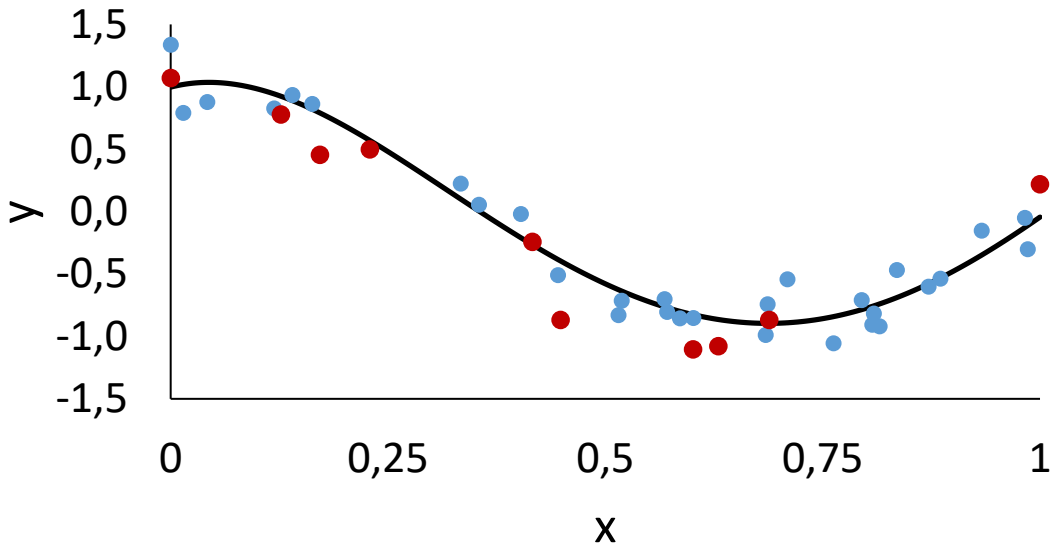
Повторяем цикл и выбираем вариант



ОДНО РАЗБИЕНИЕ — ОДИН РЕЗУЛЬТАТ

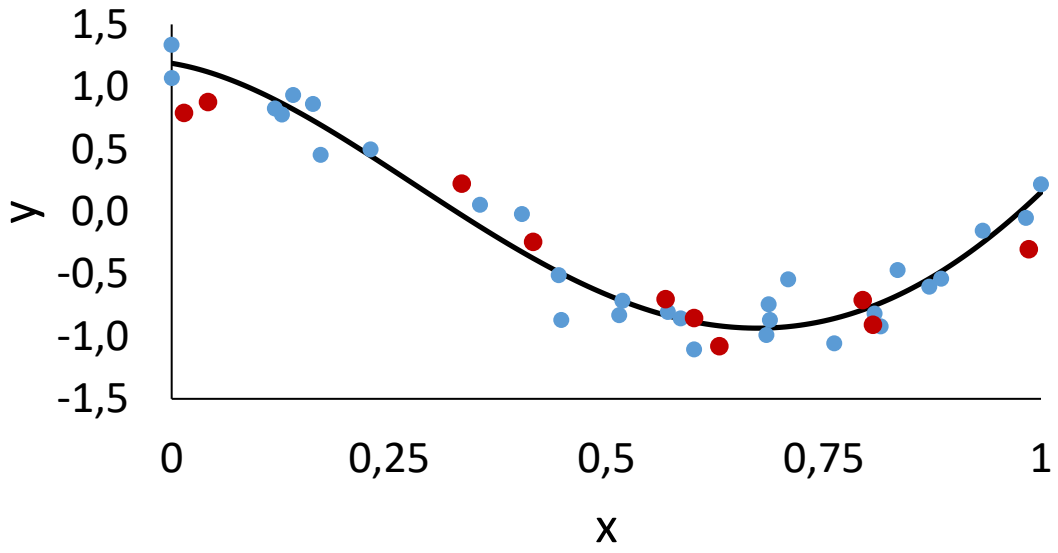
40 объектов · обучение 30 / проверка 10 · степень 4

Разделение A



RMSE проверки: 0,237

Разделение B



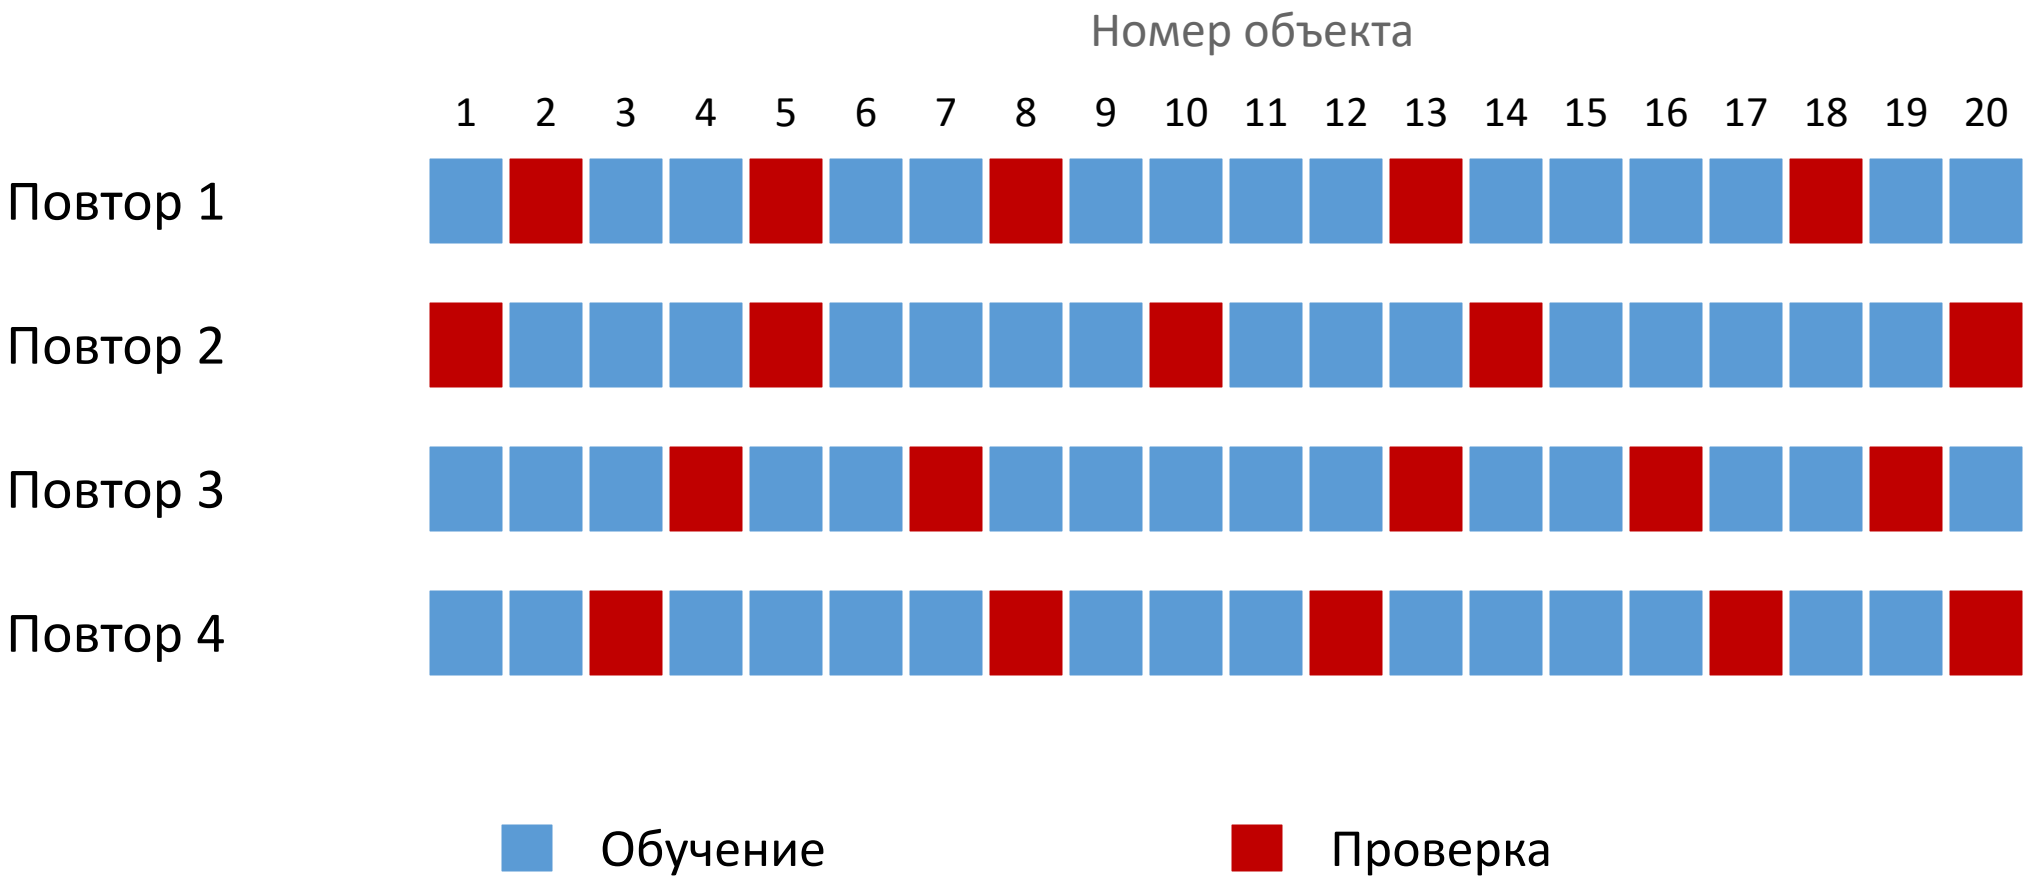
RMSE проверки: 0,221

Обучение

Проверка

ПОВТОРЯЕМ СЛУЧАЙНОЕ РАЗДЕЛЕНИЕ

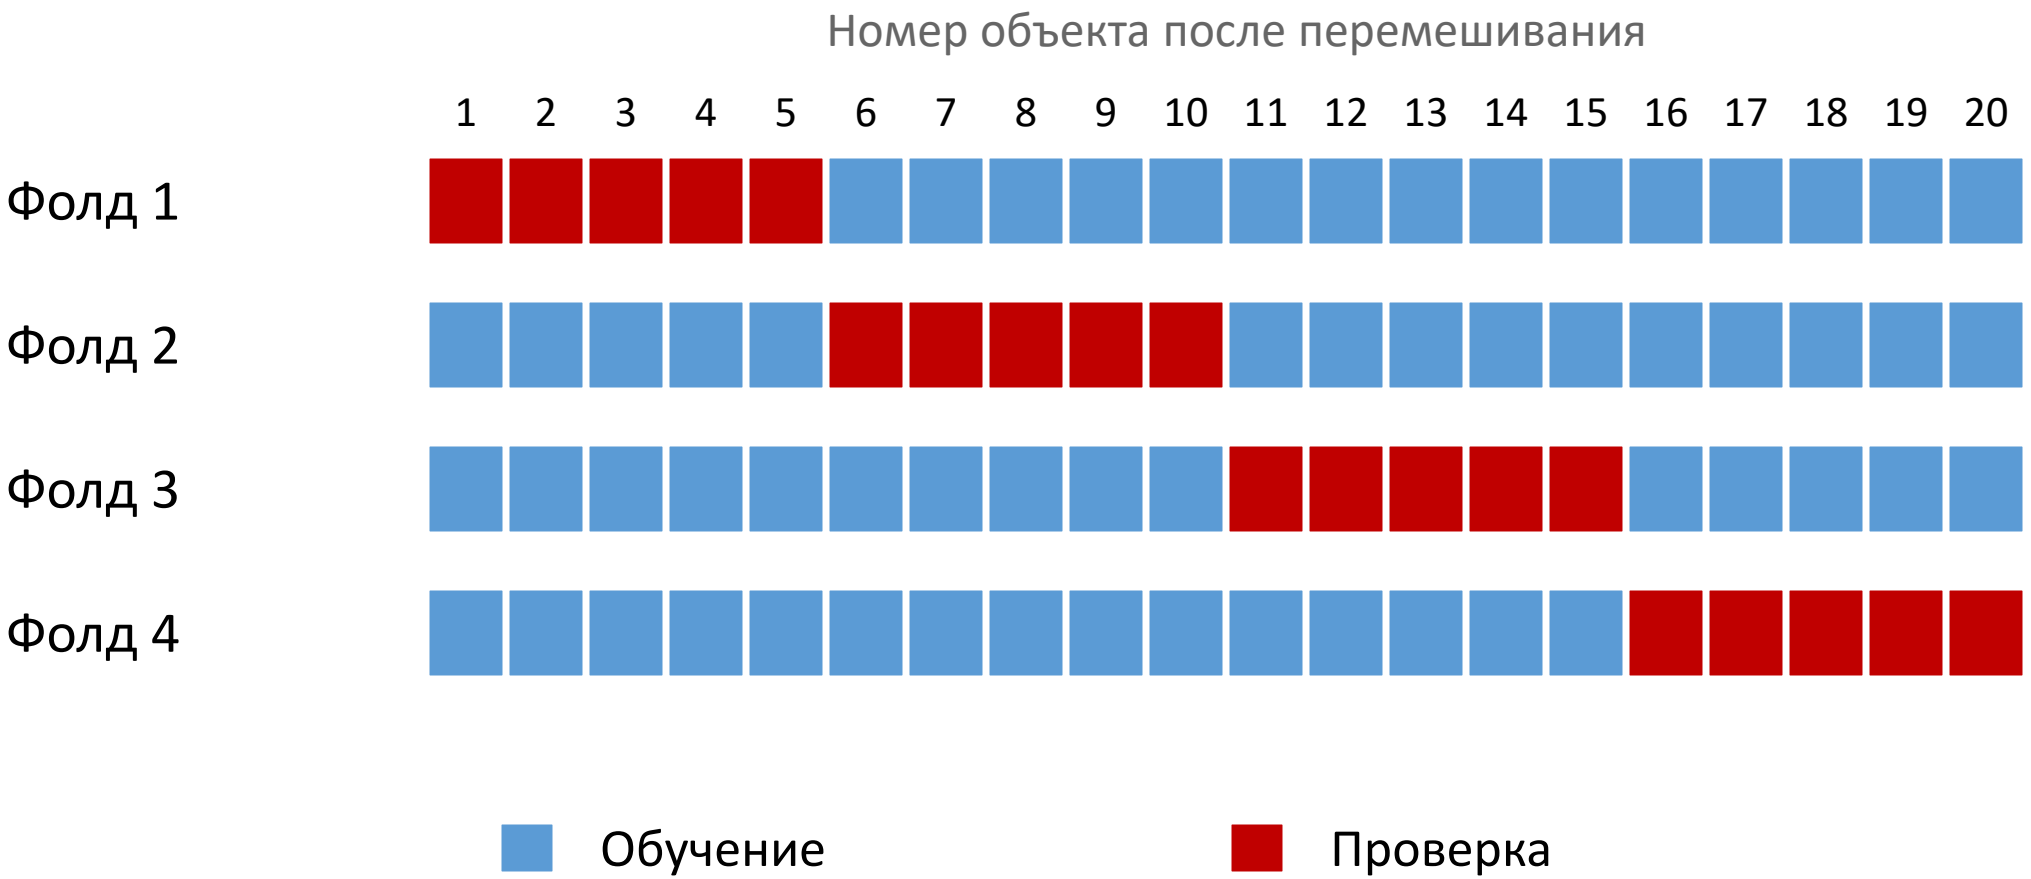
ShuffleSplit



Объект может проверяться несколько раз или ни разу

К ЧАСТЕЙ ПО ОЧЕРЕДИ

KFold · здесь K = 4



Каждый объект проверяется ровно один раз за проход

В КАЖДОМ ФОЛДЕ ОБУЧАЕМ ЗАНОВО

1. Отложить проверочную часть
2. Обучить процедуру на оставшихся данных
3. Предсказать ответы отложенных объектов
4. Вычислить и сохранить метрику
5. Перейти к следующему фолду

Все преобразования, обучаемые по данным, — внутри фолда

КАК ФОРМИРУЕТСЯ ПРОВЕРОЧНАЯ ЧАСТЬ?

Holdout

Одно разделение



ShuffleSplit

Новые случайные подмножества



KFold

Части по очереди

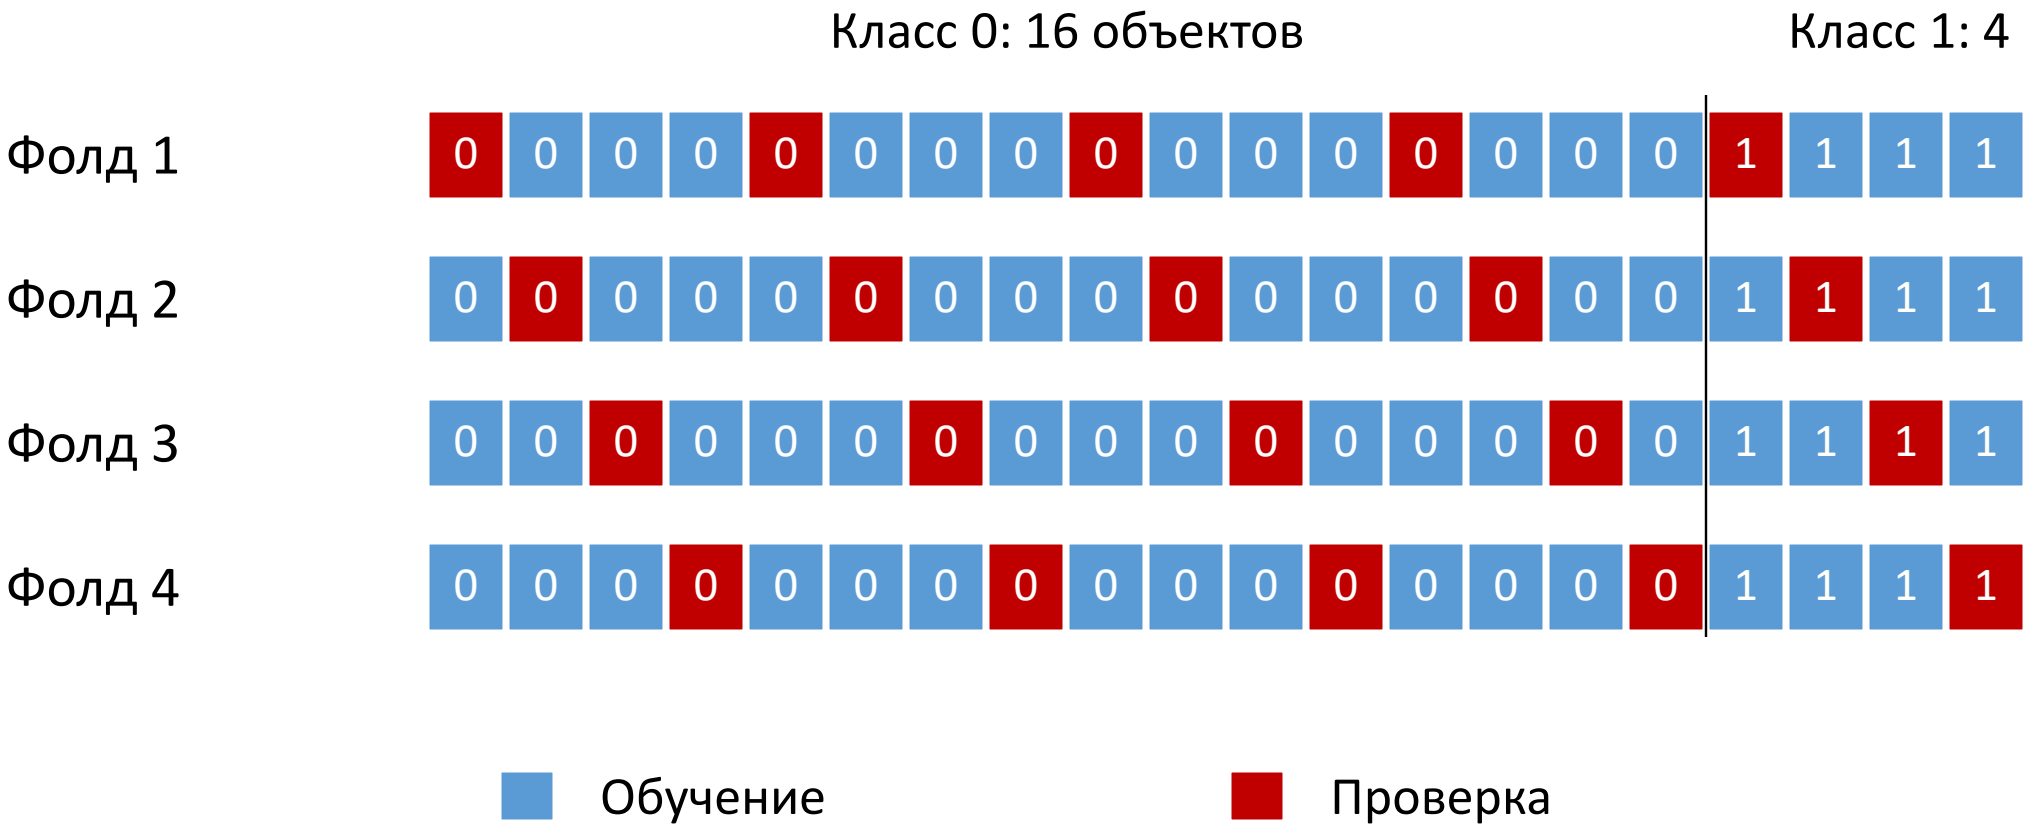


Обучение

Проверка

СОХРАНЯЕМ ДОЛИ КЛАССОВ

StratifiedKFold · схема: 16 объектов класса 0 и 4 класса 1



В каждой проверочной части: 4 + 1

РЕДКИЕ СОСТОЯНИЯ ОБЛАЧНОСТИ

Малые Кармакулы · пример из прошлого занятия

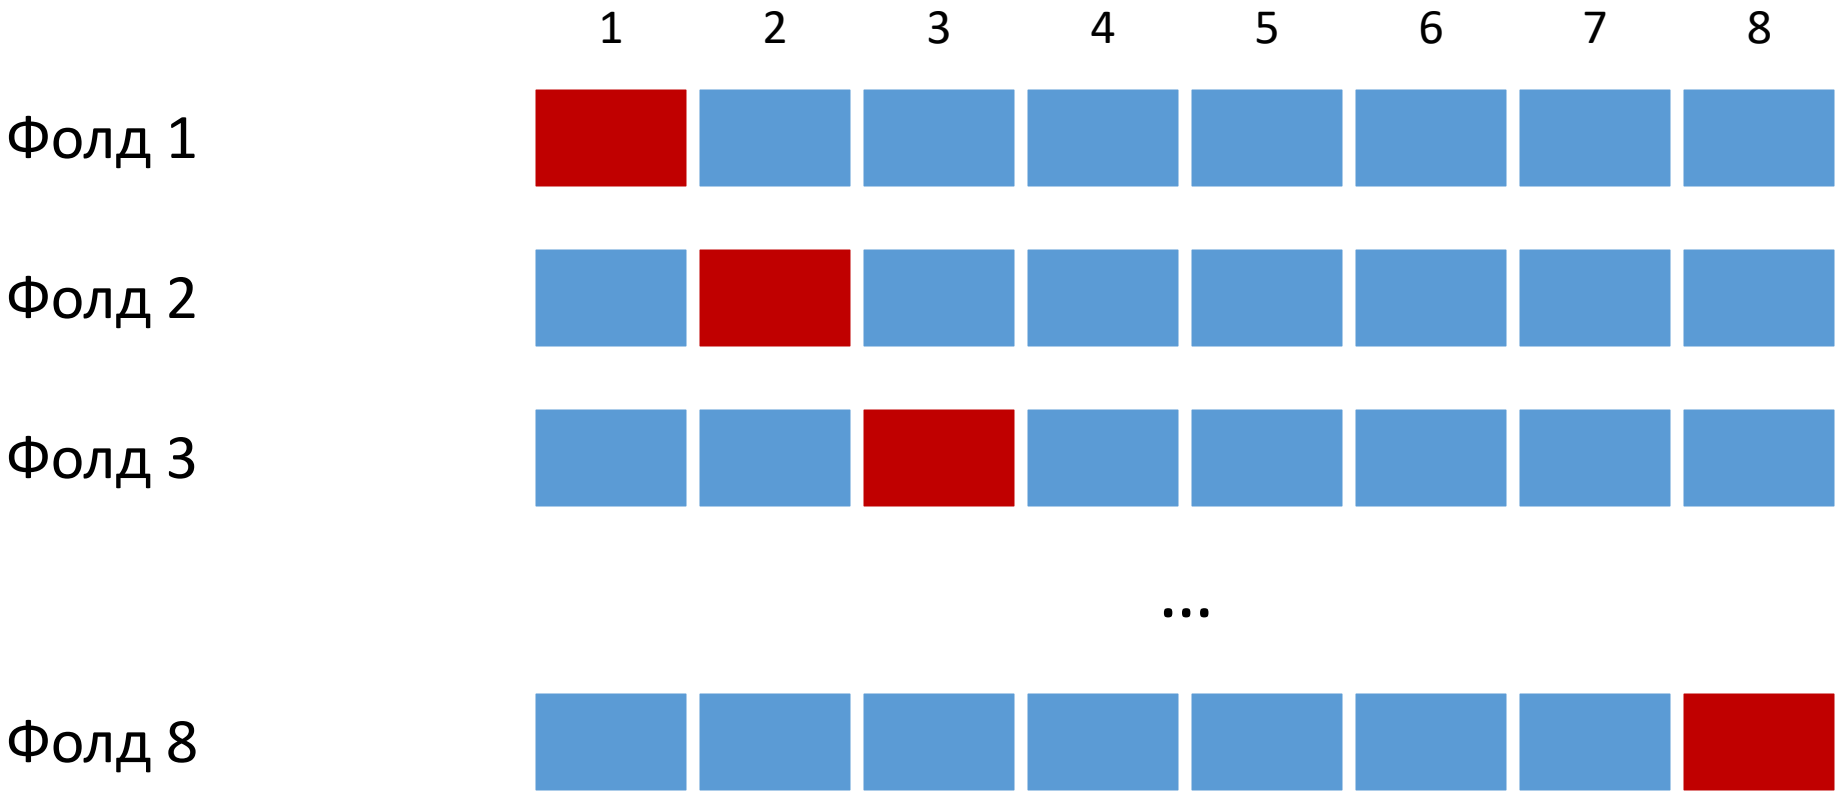
0	5	10
Ясно	Частичная облачность	Сплошная облачность

Редкий класс может не попасть в отдельный фолд

Сохранение долей не устраняет зависимость наблюдений

ОСТАВИТЬ ОДИН ОБЪЕКТ

Leave-One-Out



Обучение: N − 1 · проверка: 1 · обучений: N

СМОТРИМ ВСЕ РЕЗУЛЬТАТЫ

80 объектов · 5 фолдов · по 16 проверочных объектов

Фолд	A: степень 4
1	0,194
2	0,168
3	0,163
4	0,199
5	0,136
Среднее	**0,172**

RMSE на проверочной части каждого фолда

СРАВНИВАЕМ НА ОДНИХ РАЗБИЕНИЯХ

Меняем модель, сохраняем состав фолдов

Фолд	A: степень 4	B: степень 12
1	0,194	0,221
2	0,168	0,164
3	0,163	0,185
4	0,199	0,217
5	0,136	0,197
Среднее	**0,172**	**0,197**

Один удачный фолд ещё не определяет лучший вариант

ЧТО ИМЕННО УСРЕДНЯЕМ?

Два агрегата для модели A из той же проверки

Среднее RMSE по фолдам

$$(1/K) \sum r_k$$

0,17199

RMSE по всем OOF-ответам

$$\sqrt{\left[\sum n_k r_k^2 / \sum n_k \right]}$$

0,17351

OOF: каждый ответ получен без обучения на этом объекте

Для сравнения моделей выбираем один способ агрегации

РАЗБРОС МЕЖДУ ФОЛДАМИ

Среднее и std описывают результаты этой проверки

Среднее	std
0,1720	0,0229

Обучающие части фолдов пересекаются

Разброс фолдов не даёт готовый доверительный интервал

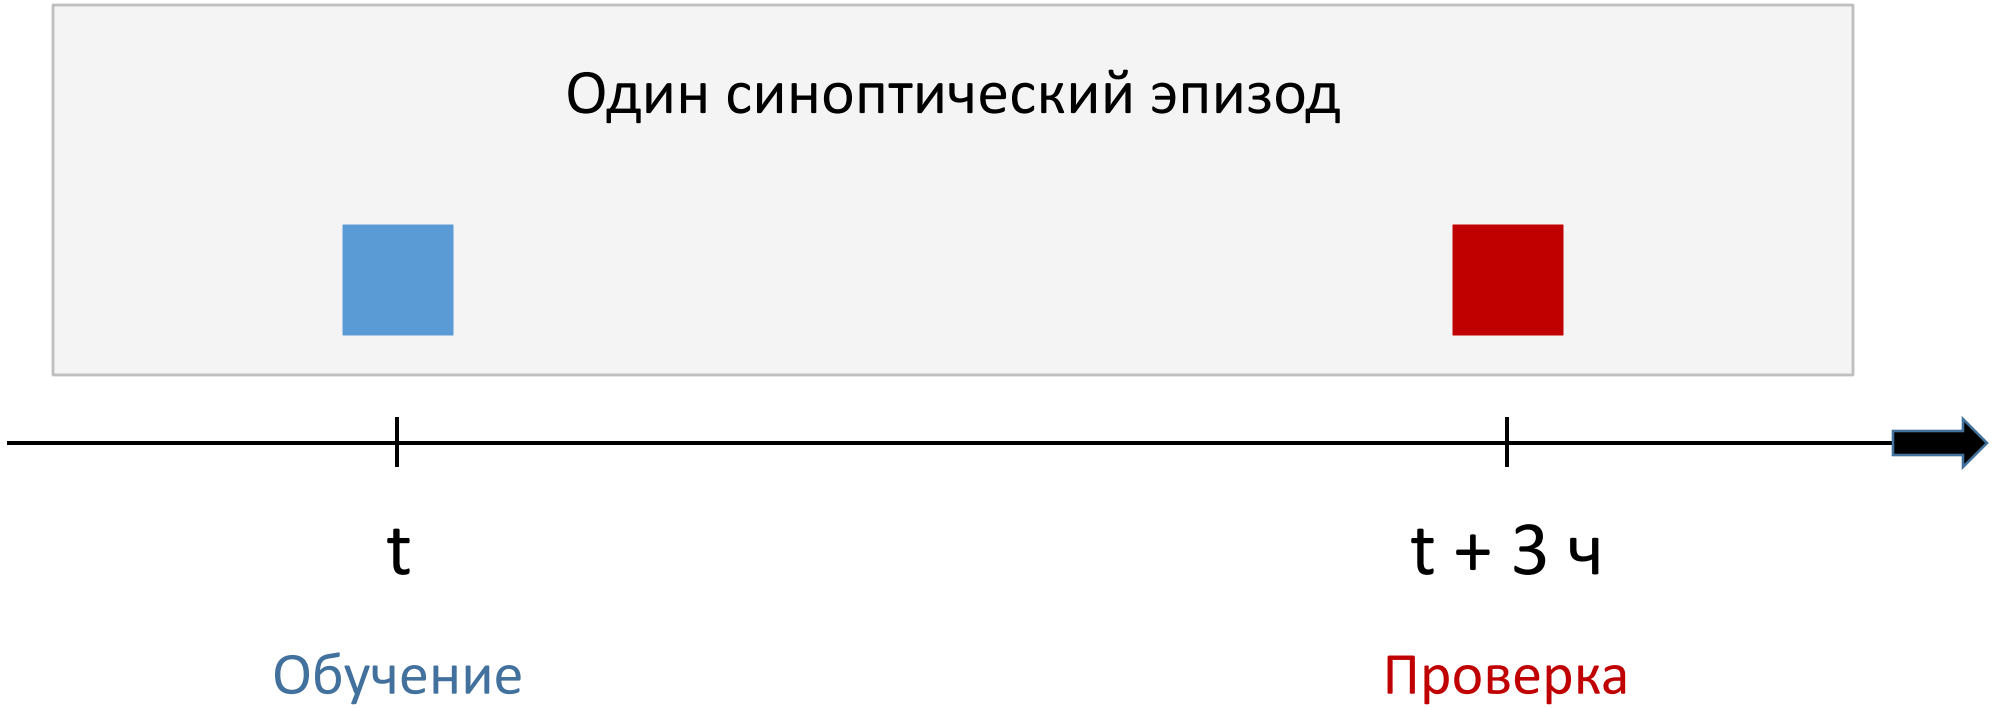
ЧТО БУДЕТ НОВЫМ ОБЪЕКТОМ?

1. Следующий срок
2. Новое синоптическое событие
3. Будущий год
4. Другая станция

Схема проверки следует условиям применения модели

СОСЕДНИЙ СРОК — НОВЫЙ ПРИМЕР?

Два наблюдения одного циклона



Далее: как учитывать время, события и место наблюдений?