ML4hydromet-2026

Занятие №2.
Технические средства анализа данных.

Разведочный анализ данных.



Преподаватели:
Михаил Иванович Варенцов, к.г.н.
Михаил Алексеевич Криницкий, к.т.н.
ml4hydromet@ml4es.ru

Репозиторий курса

ML4hydromet-2026

Курс "Машинное обучение в гидрометеорологии" для магистров I года обучения географического факультета МГУ.

Преподаватели: **Михаил Варенцов** (ИСТИНА, ResearchGate) и **Михаил Криницкий** (персональная страница, ResearchGate).

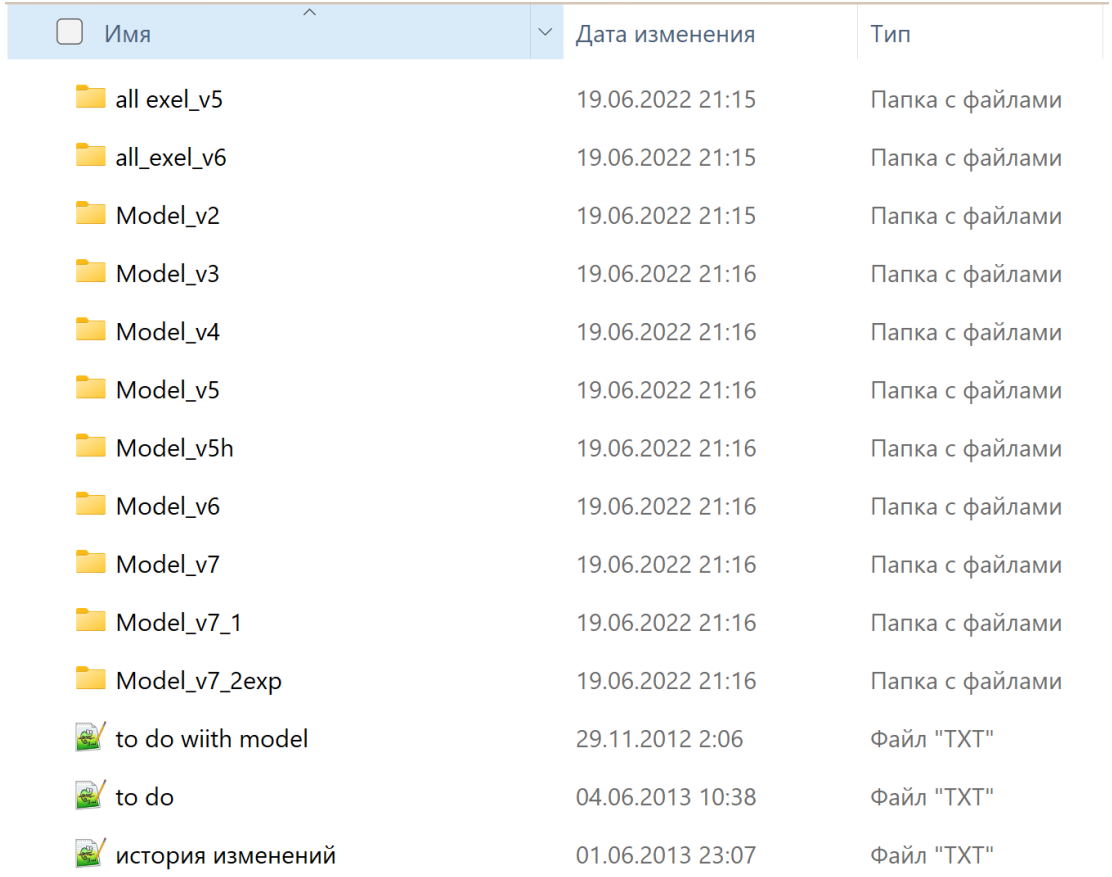
Предыдущии версии курса: ML4hydromet-2024, ML4hydromet-2025

Материалы по курсу

Название	Дата	Тема	Материалы
Занятие 1	02.10.2026	Организационные вопросы. Готовые коллекции данных. Введение в машинное обучение.	Презентация (MV) Презентация (MK) Видеозапись - ч.1 Видеозапись - ч.2 Видеозапись - ч.3

https://github.com/mvarentsov/ML4hydromet-2026

Что такое git-репозиторий?

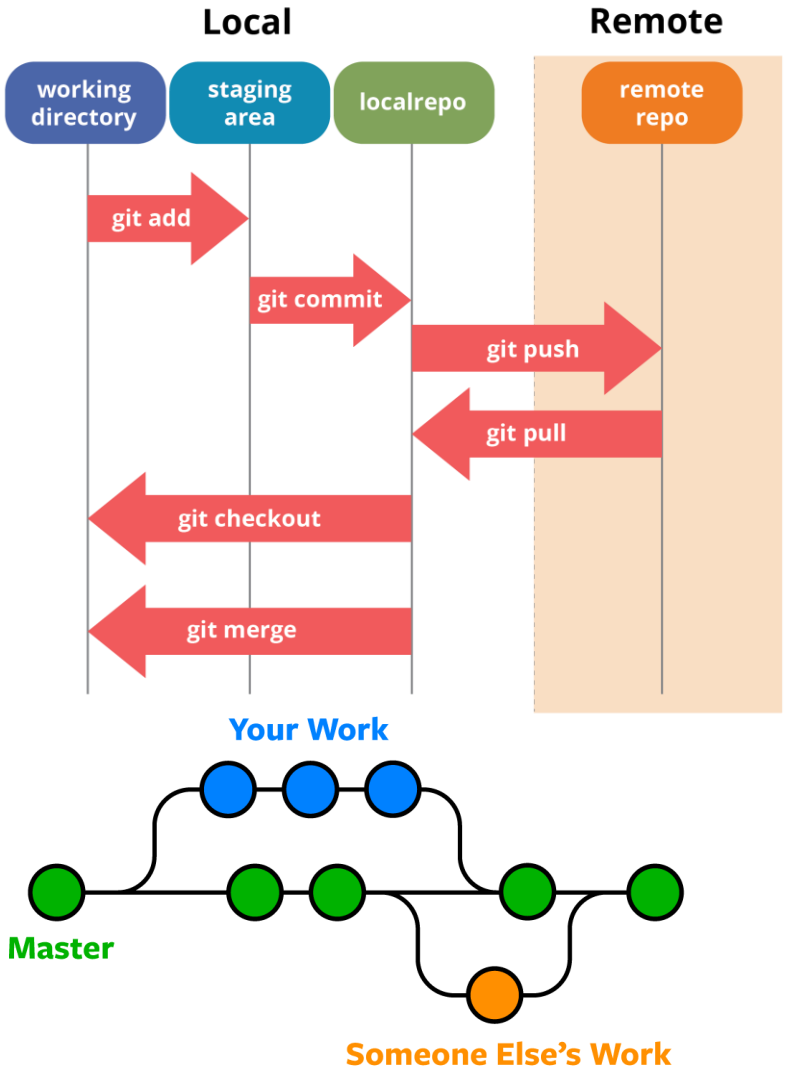


Имя	Дата изменения	Тип
all exel_v5	19.06.2022 21:15	Папка с файлами
all_exel_v6	19.06.2022 21:15	Папка с файлами
Model_v2	19.06.2022 21:15	Папка с файлами
Model_v3	19.06.2022 21:16	Папка с файлами
Model_v4	19.06.2022 21:16	Папка с файлами
Model_v5	19.06.2022 21:16	Папка с файлами
Model_v5h	19.06.2022 21:16	Папка с файлами
Model_v6	19.06.2022 21:16	Папка с файлами
Model_v7	19.06.2022 21:16	Папка с файлами
Model_v7_1	19.06.2022 21:16	Папка с файлами
Model_v7_2exp	19.06.2022 21:16	Папка с файлами
to do wiith model	29.11.2012 2:06	Файл "TXT"
to do	04.06.2013 10:38	Файл "TXT"
история изменений	01.06.2013 23:07	Файл "TXT"

- Git - система управления версиями
- Придумал Линус Торвальдс при разработке ядра Линукс
- Современный стандарт для совместной разработки, в том числе в научной сфере и Data Science
- Задачи Git:
  - Синхронизация
  - Резервное копирование
  - Отслеживание и отмена изменений
  - Командная работа

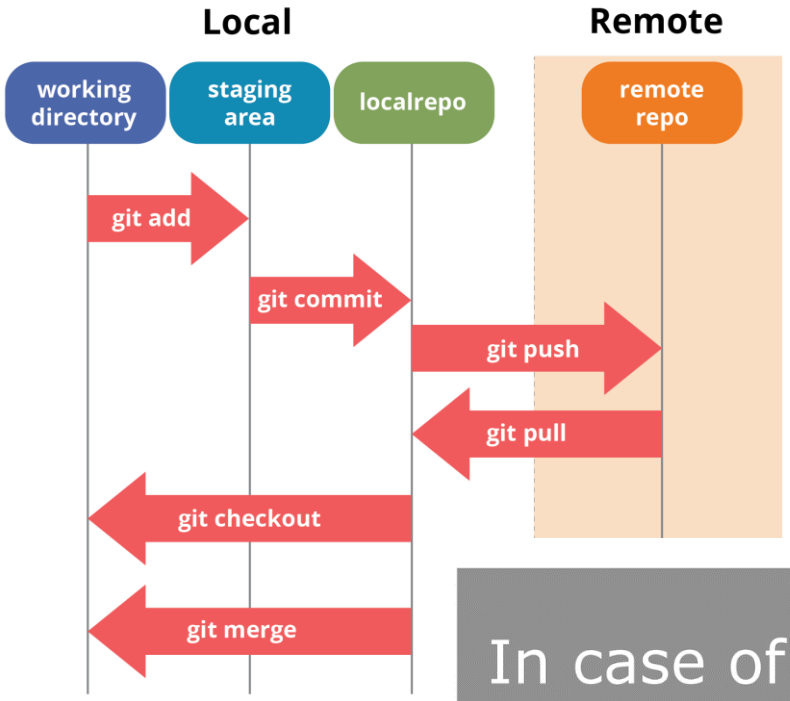
Что такое git-репозиторий?

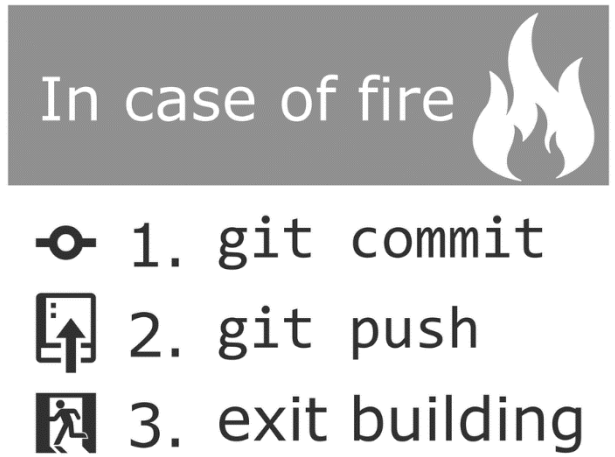
- **Репозиторий** — место, где хранится код (или данные)
  - Локальный
  - Удаленный (remote)
- **Коммит (commit)** — зафиксированное и неизменяемое состояние репозитория. Чаще всего их создают, когда:
  - Создан новый функционал
  - Добавлен новый блок на верстке
  - Исправлены ошибки по коду
  - Завершен рабочий день
- **Ветка (branch)** - независимая последовательность коммитов в хронологическом порядке



Что такое git-репозиторий?

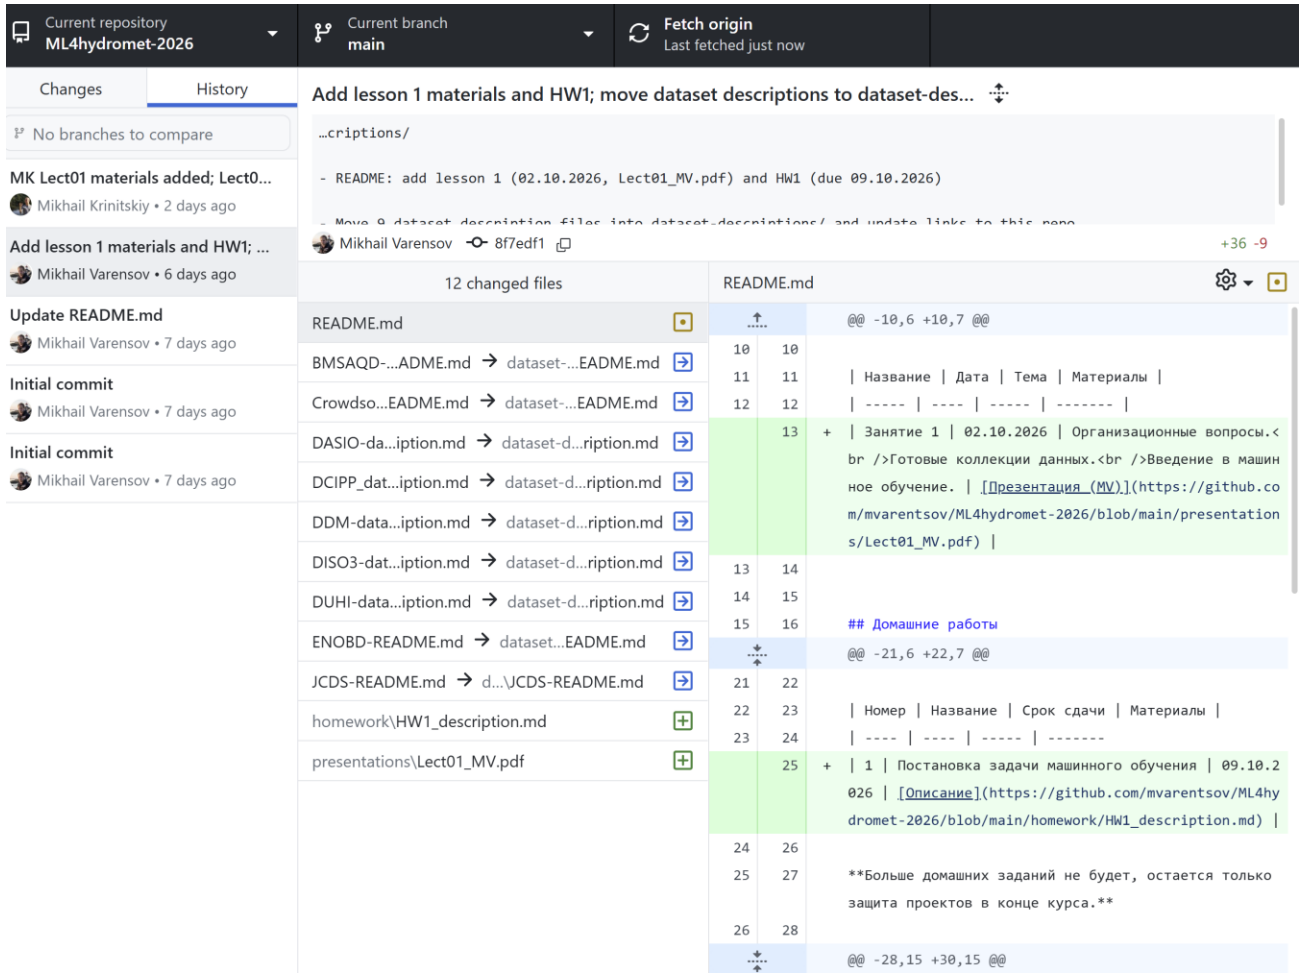
- **git clone** - получения локальной копии существующего Git-репозитория
  `git clone git@github.com:mvarentsov/ML4hydromet-2026.git`
- **git fetch** - загрузка содержимого из удаленного репозитория (без изменения локального репозитория)
- **git pull = Git fetch + Git merge -** загрузка содержимого из удаленного репозитория и обновление локального репозитория
- **git add** - добавить файл в список тех, которые отслеживаются для текущего коммита
- **git commit** - зафиксировать текущие изменения
- **git push** - выгрузка содержимого локального репозитория в удаленный репозиторий.



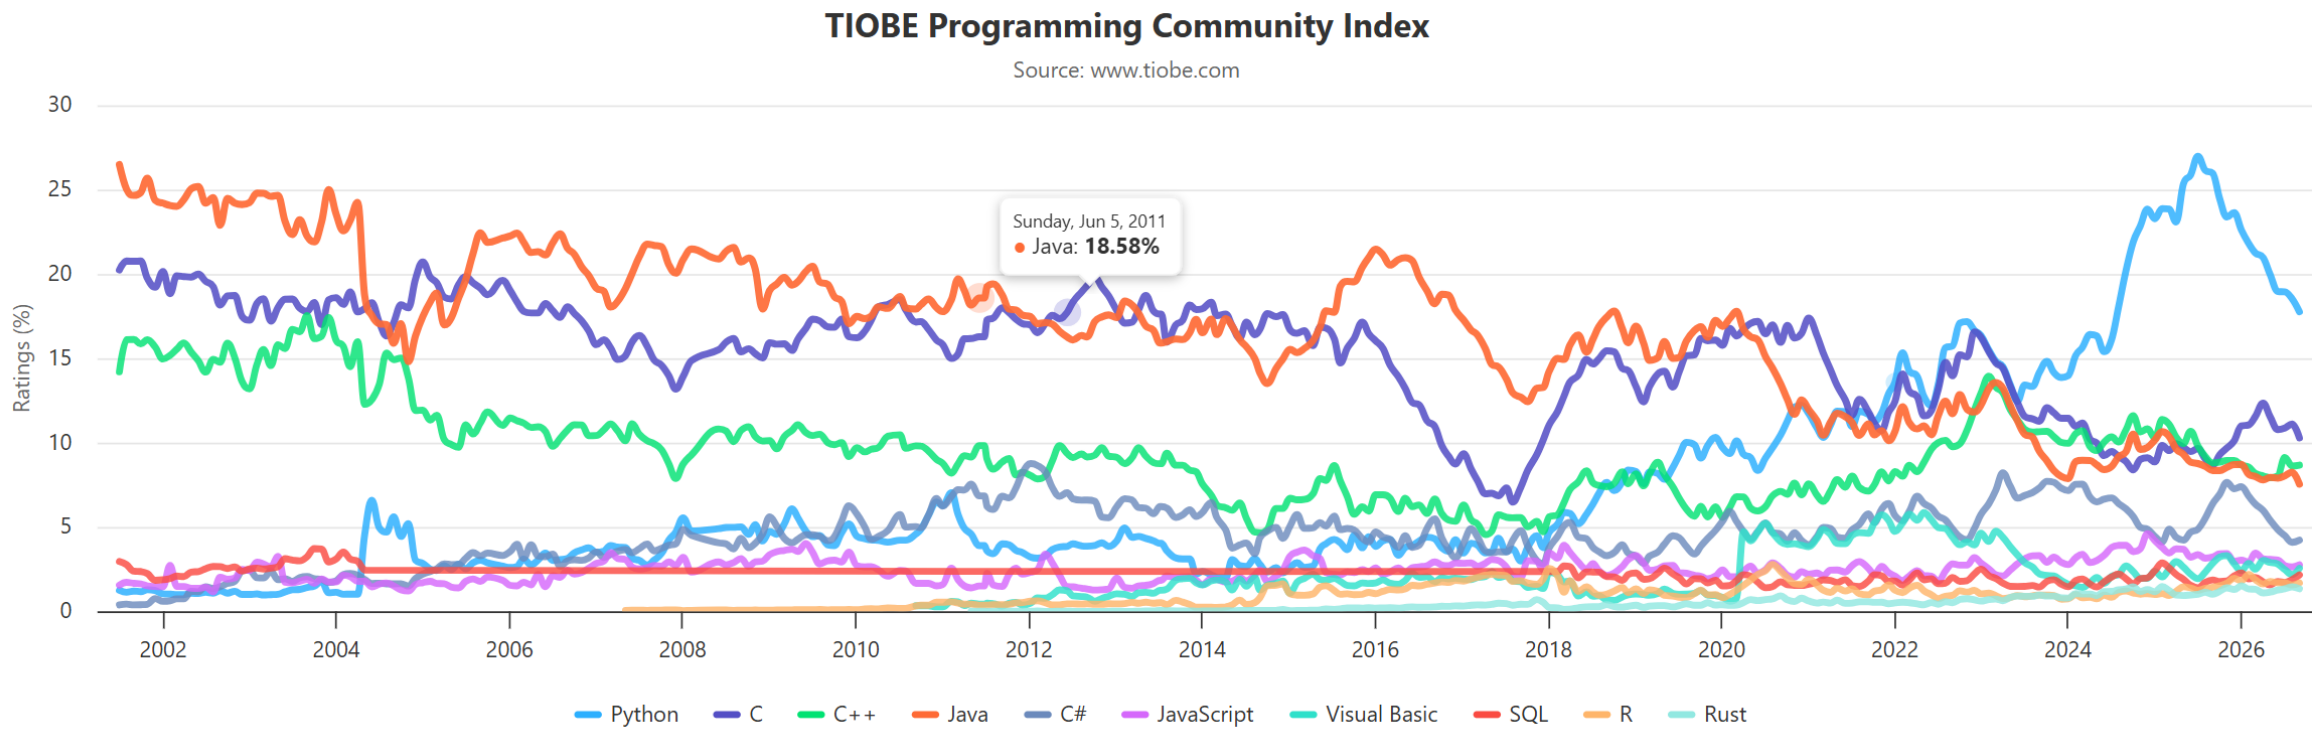


Что такое git-репозиторий?

- **GitHub - облачный Git-сервер**
  - Альтернатива - создать собственный сервер, например на базе GitLab
- **GitHub Desktop - графический клиент для GitHub.**
- **Интеграции во многие современные IDE**
- **Есть и альтернативы**
  - Встроенные в IDE
  - Sourcetree (Windows, macOS и Linux)
  - GitKraken (Windows, macOS)

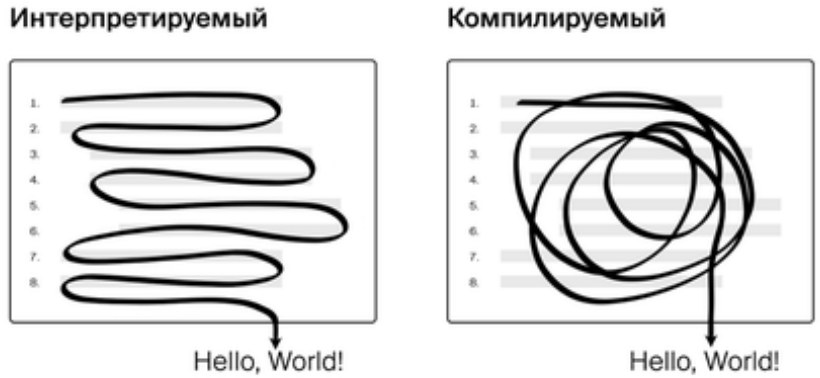


Python для анализа данных



Рейтинг TIOBE (TIOBE Index) — это ежемесячный индекс, который отражает популярность языков программирования. Он основан на количестве поисковых запросов в различных поисковых системах, таких как Google, Bing, Yahoo!, Wikipedia и других.

Экосистема python



- Python – интерпретируемый* язык (наряду с R, Matlab, Julia и др.).
  - Исполняется ровно точно то, что написано
  - Исполняется построчно*
  - Логические ошибки идентифицируются в момент исполнения
- Ключевые элементы экосистемы:
  - **Дистрибутив Python** (например Anaconda для Data Science, Miniconda, WinPython)
  - **Среда выполнения (ядро, kernel):** CPython, IPython, локально или удаленно (Google Colab и пр).
  - **Веб-интерфейсы:** Jupiter Notebook, Jupiter Lab
  - **Среды разработки (IDE):** VS Code, PyCharm, Spyder
  - **Пакетный менеджер** (pip, conda)
  - **Окружение (environment)**

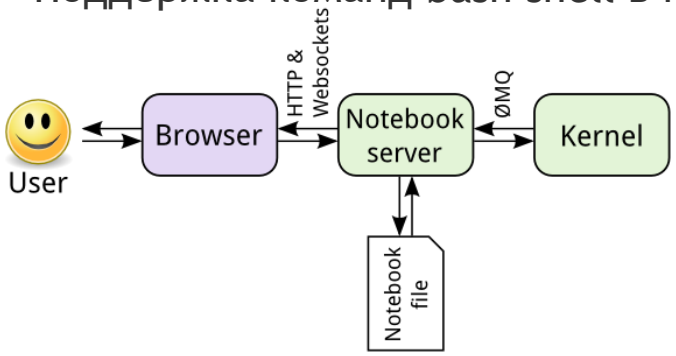
python™

ANACONDA®

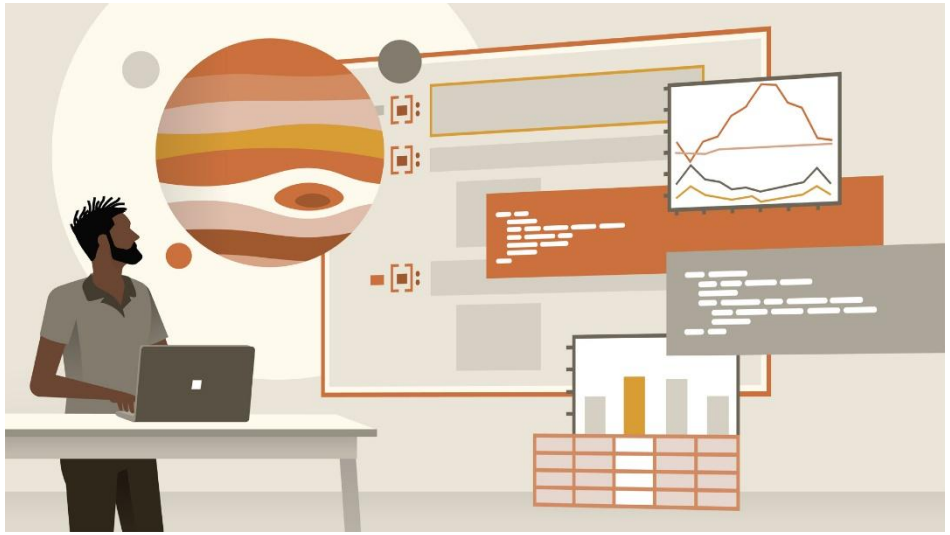
jupyter

Jupiter Notebook

- Поддержка разных языков программирования (Ju-Py-teR = Julia, Python & R, и не только) через механизм ядер (kernels)
  - Ядро (например, ipykernel для Python) — это отдельный процесс, который выполняет код из ячеек, хранит в оперативной памяти все переменные и общается с интерфейсом (браузером/IDE)
- Поэтапное и нелинейное исполнения (важно об этом помнить)
- Комбинирование контента: объединение вместе исходного кода, результатов его выполнения, повествовательный текст (с использованием Markdown), формулы (LaTeX) и др.
- Интерактивные графики и элементы
- Платформонезависимость, поддержка разными IDE
- Поддержка команд bash shell в коде python (jupiter magic)



Всегда проверяйте "Restart & Run All" перед сдачей работы!



nature

Explore content | About the journal | Publish with us | Subscribe

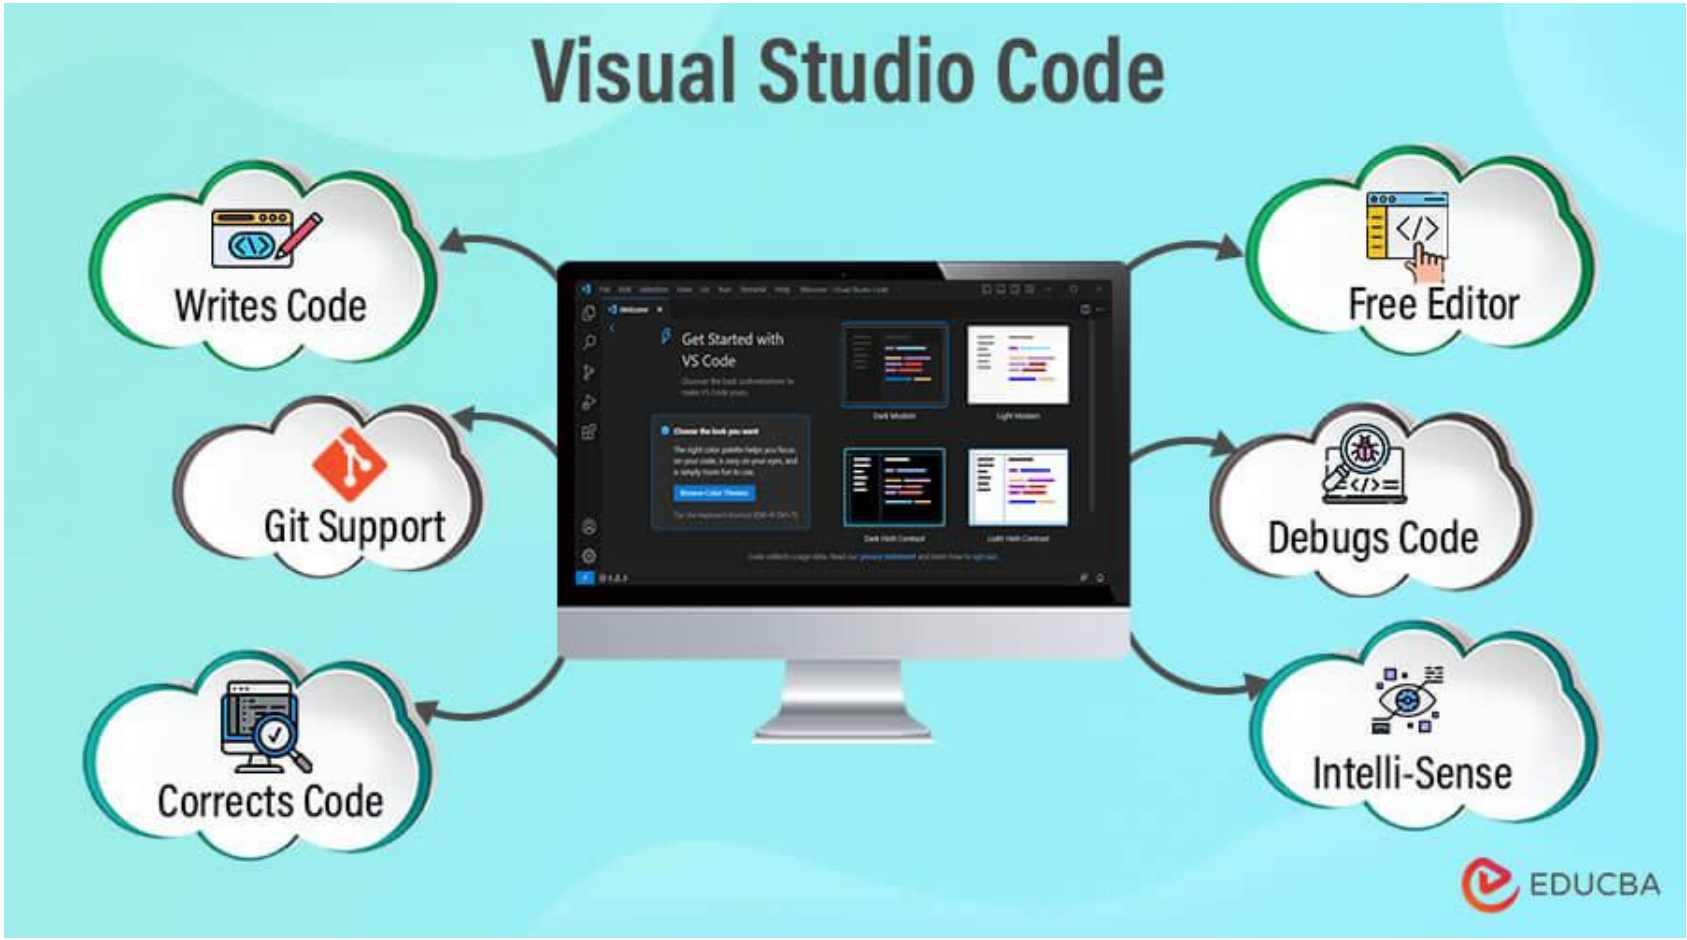
nature › toolbox › article

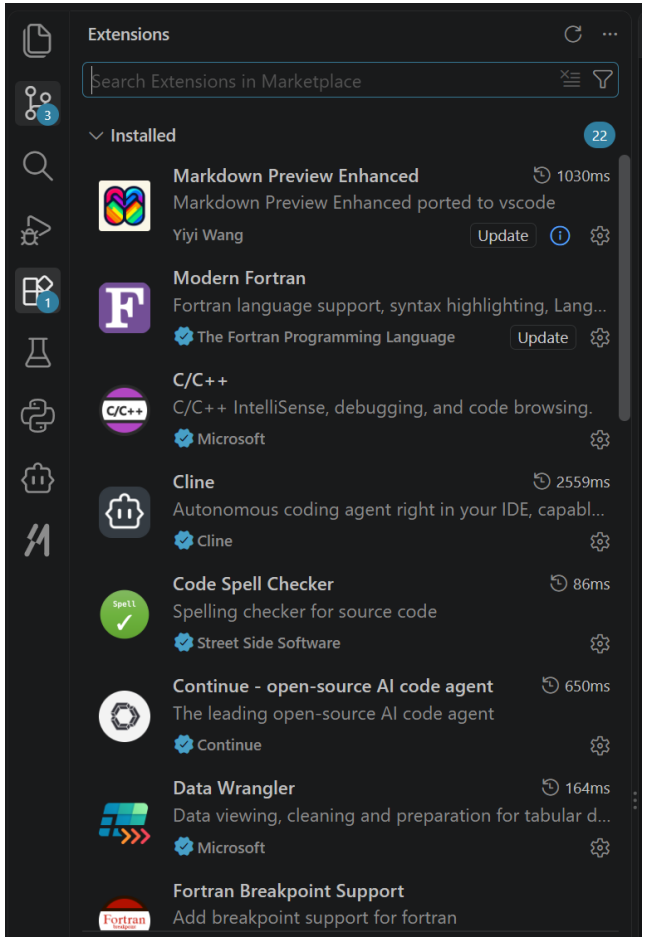
TOOLBOX | 30 October 2018

Why Jupyter is data scientists' computational notebook of choice

An improved architecture and enthusiastic user base are driving uptake of the open-source web tool.

VS code IDE





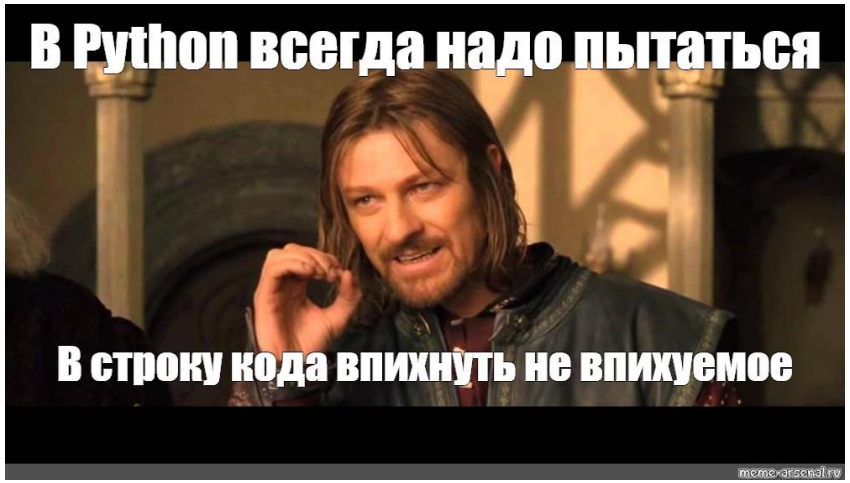
https://code.visualstudio.com/

Особенность Python



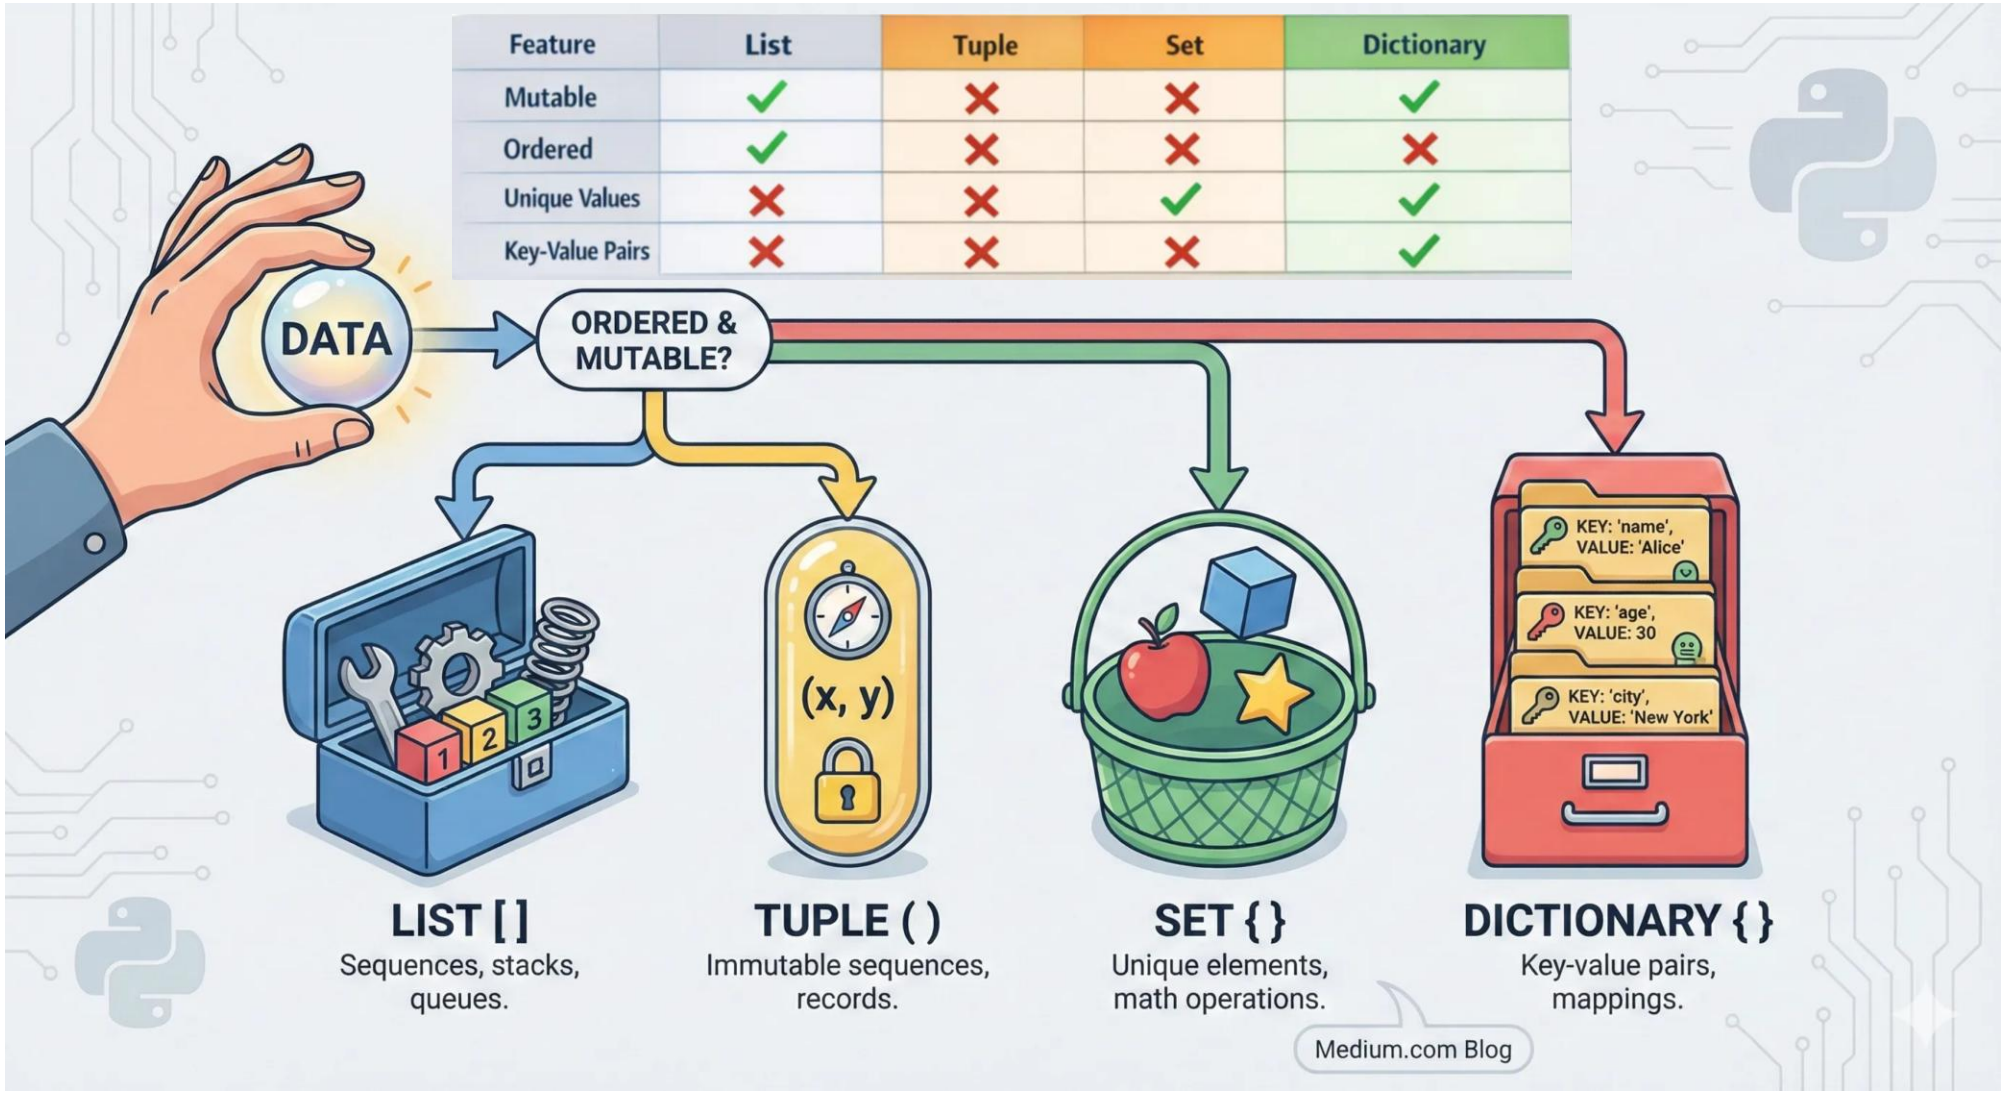
Only Python programmers will understand 😏







Базовые коллекции данных



Функции и классы

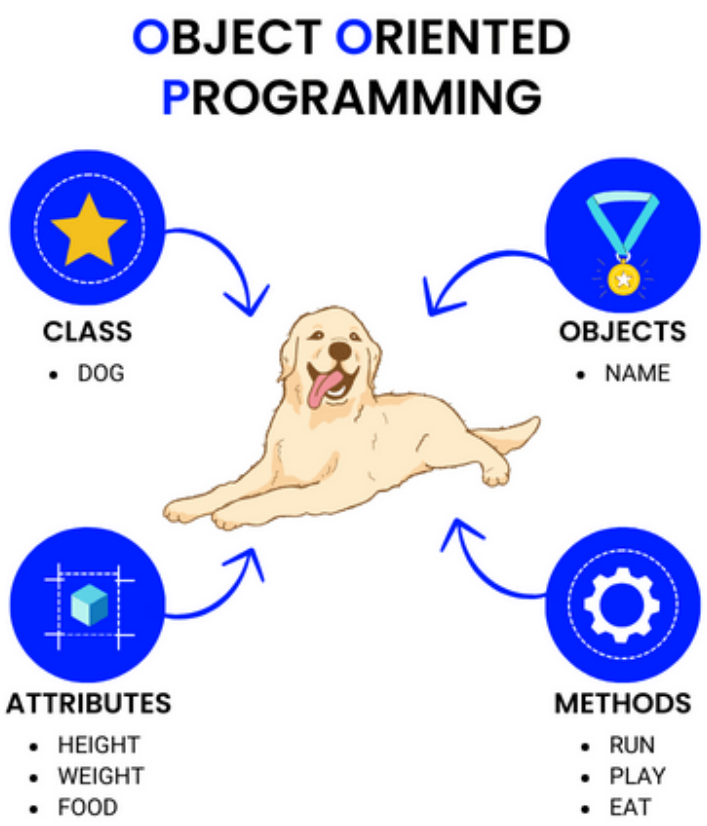
```python
def double(x):
  return x * 2

def add_one(x):
  return x + 1

print(double(add_one(1)))

# result:
# 4

```




```python
class Dog:
    def __init__(self, weight, height, breed, name):
        self.weight = weight
        self.height = height
        self.breed = breed
        self.name = name

    def info(self):
        return "Hello my name is {}".format(self.name)

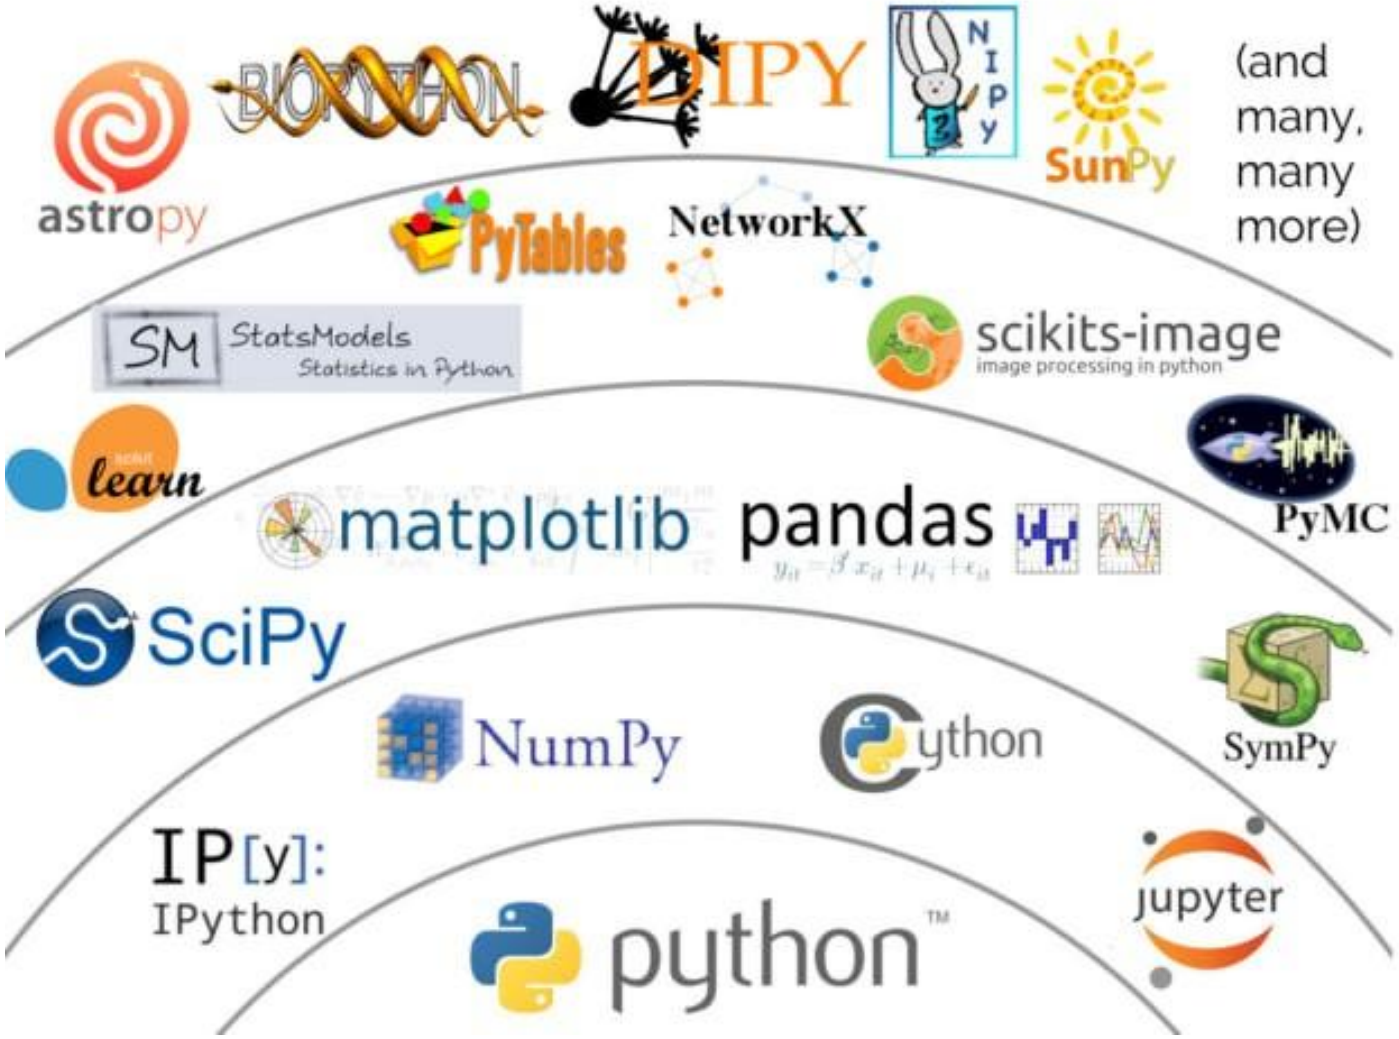
    def bark(self):
        return "The {} is barking".format(self.breed)

    def bmi(self):
        return int(self.weight / self.height)


Dog1 = Dog(30, 50, "golden retriever", "Terry the Legend")
Dog2 = Dog(900, 4, "poodle", "Fluffy the Amazing")

print(Dog1.info())
print(Dog1.bark())
print(Dog2.bmi())
```

Python для анализа данных



Python для анализа данных

Наиболее важные для нашего курса:

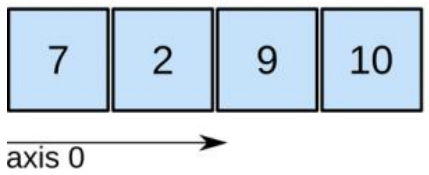
- ❑ NumPy – работа с многомерными массивами и матрицами, математические операции
- ❑ Pandas – работа табличными данными
- ❑ Maplotlib – графики на все случаи жизни с ручной настройкой
- ❑ Scikit-learn – базовый уровень машинного обучения
- ❑ Pytorch – глубокое обучение (нейросети)
- ❑ Scipy – статистический анализ

Также могут пригодится:

- ❑ Xarray – работа с многомерными массивами данных, имеющих пространственно-временную привязку (netcdf, grib, hdf)
- ❑ Seaborn – продвинутые высокоуровневые графики
- ❑ Ploty – интерактивные кросс-платформенные графики
- ❑ Rasterio – работа с пространственными растровыми данными (geotiff)
- ❑ Shapely, geopandas – работа с векторными пространственными данными

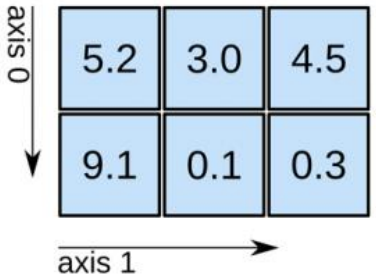


Numpy: многомерные массивы



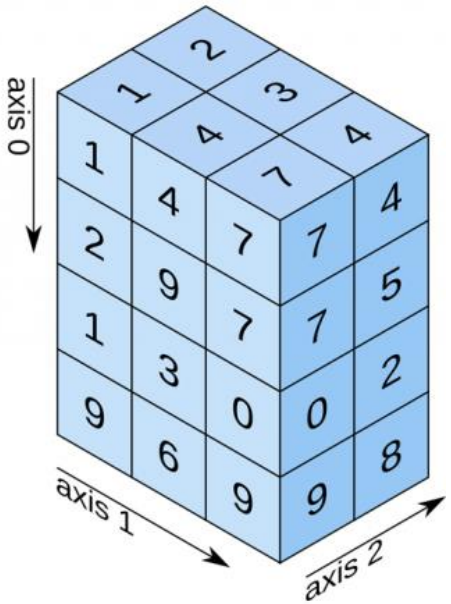
1D array

shape: (4,)



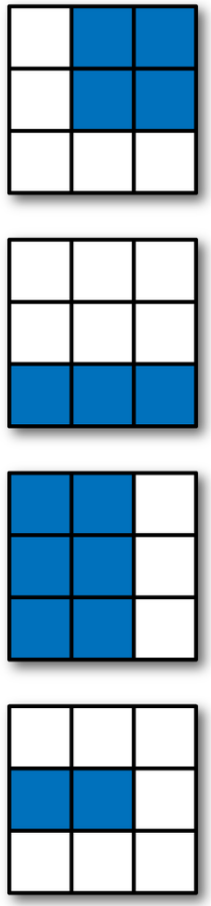
2D array

shape: (2, 3)



3D array

shape: (4, 3, 2)



Expression	Shape
`arr[:2, 1:]`	`(2, 2)`
`arr[2]`	`(3,)`
`arr[2, :]`	`(3,)`
`arr[2:, :]`	`(1, 3)`
`arr[:, :2]`	`(3, 2)`
`arr[1, :2]`	`(2,)`
`arr[1:2, :2]`	`(1, 2)`

Numpy: многомерные массивы

Feature	Python List	NumPy Array
Data Type	Mixed types allowed	Single type only
Speed	Slower	Much faster
Memory	Higher usage	Optimized & compact
Operations	Loop-based, manual	Vectorize(element-wise)
Use Case	General storage	Numerical computing & ML

```python
# Create two arrays
array1 = np.array([1, 2, 3, 4])
array2 = np.array([10, 20, 30, 40])

# Perform element-wise addition (vectorized)
result = array1 + array2
print(result)  # Output: [11, 22, 33, 44]
```

Vectorization example

```python
# Using Python loop (Non-vectorized)
array1 = [1, 2, 3, 4]
array2 = [10, 20, 30, 40]
result = []
for i in range(len(array1)):
    result.append(array1[i] + array2[i])  # Slower
```

Non- Vectorized Example

Pandas: прямоугольные данные

Ключевые термины для прямоугольных данных

Кадр данных (data frame)

Прямоугольные данные (подобно электронной таблице) — это базовая структура данных для статистических и автоматически обучающихся моделей.

Признак (feature)

Столбец в таблице обычно называется признаком.

Синонимы: атрибут, вход, предсказатель, предиктор, переменная.

Исход (outcome)

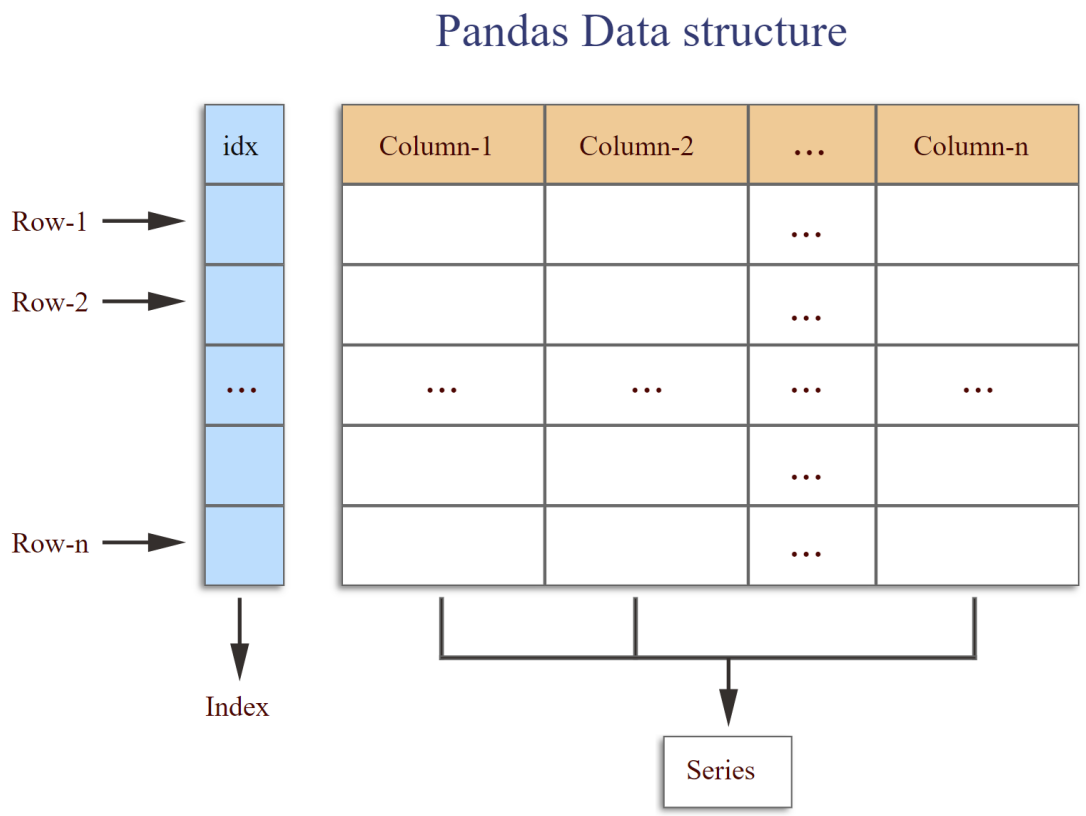
Многие проекты науки о данных предусматривают с предсказание исхода — нередко в формате да/нет (например, в табл. 1.1 это ответ на вопрос "Были ли торги состязательными или нет?"). Признаки иногда используются для предсказания исхода в эксперименте или статистическом исследовании.

Синонимы: результат, зависимая переменная, отклик, цель, выход.

Записи (records)

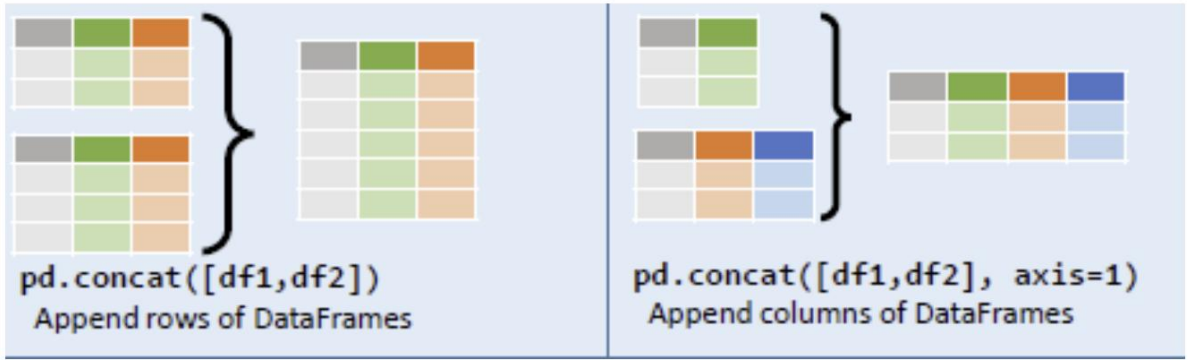
Строка в таблице обычно называется записью.

Синонимы: случай, пример, прецедент, экземпляр, наблюдение, шаблон, патерн, образец.

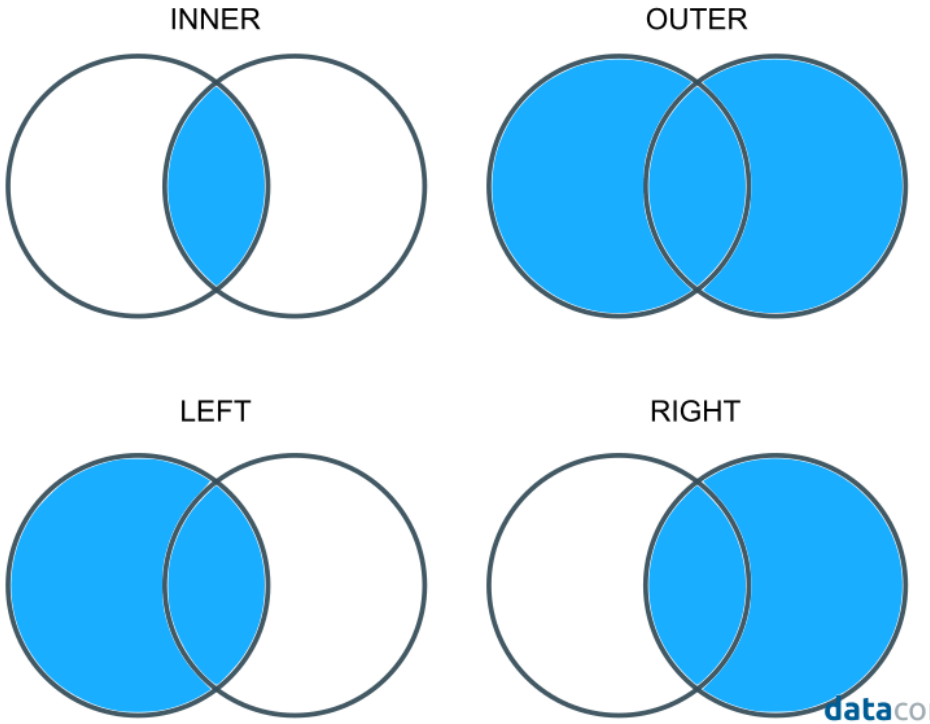


Pandas: конкатенация

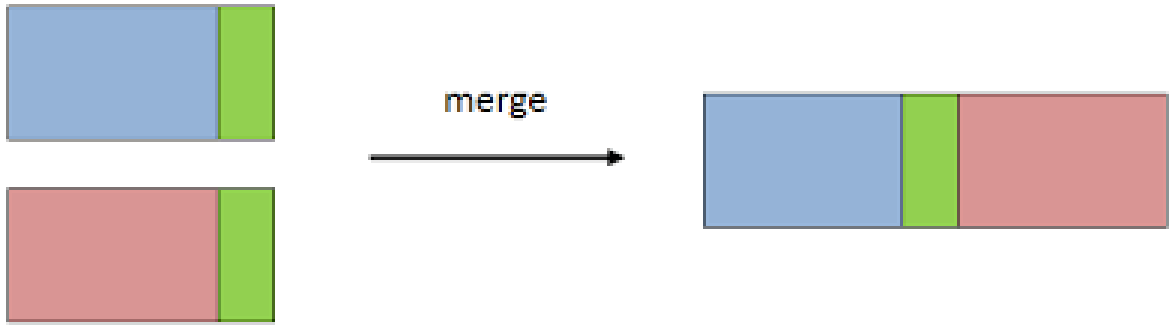
pd.concat



DataFrame.join

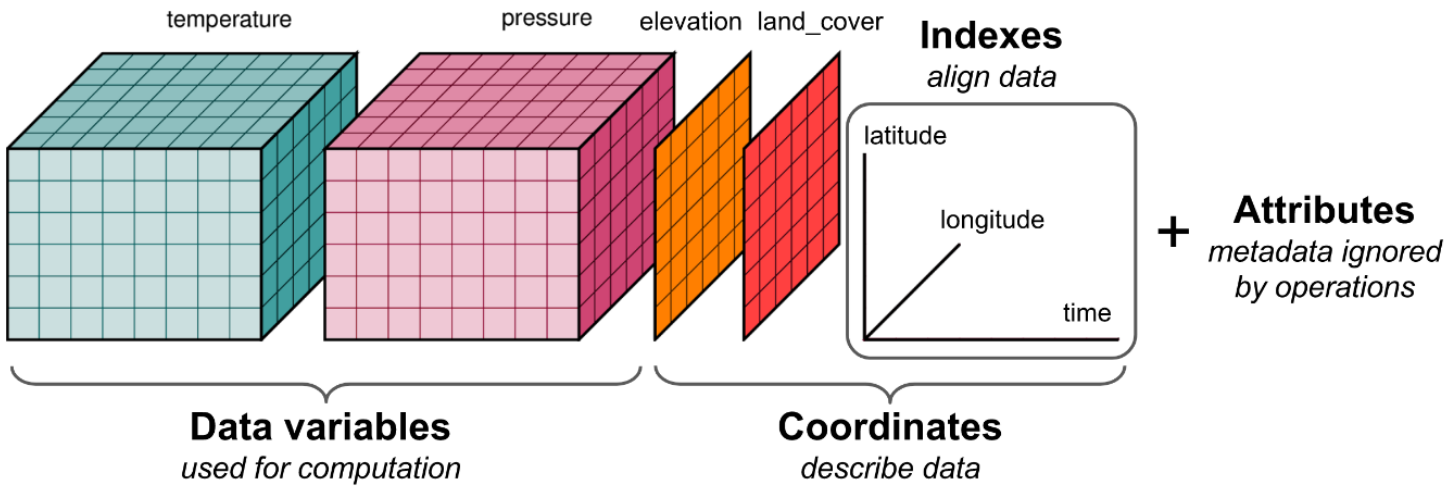


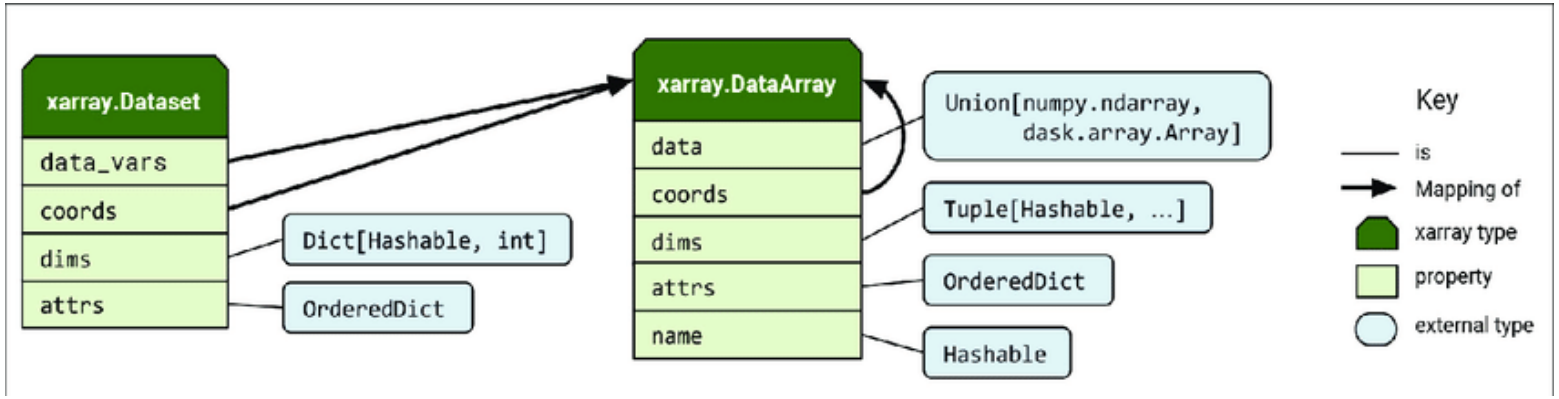
pd.merge



- Функция **join()** объединяет два кадра данных по индексу.
- Функция **merge()** объединяет два кадра данных по любому указанному вами столбцу.

Xarray: многомерные геоданные

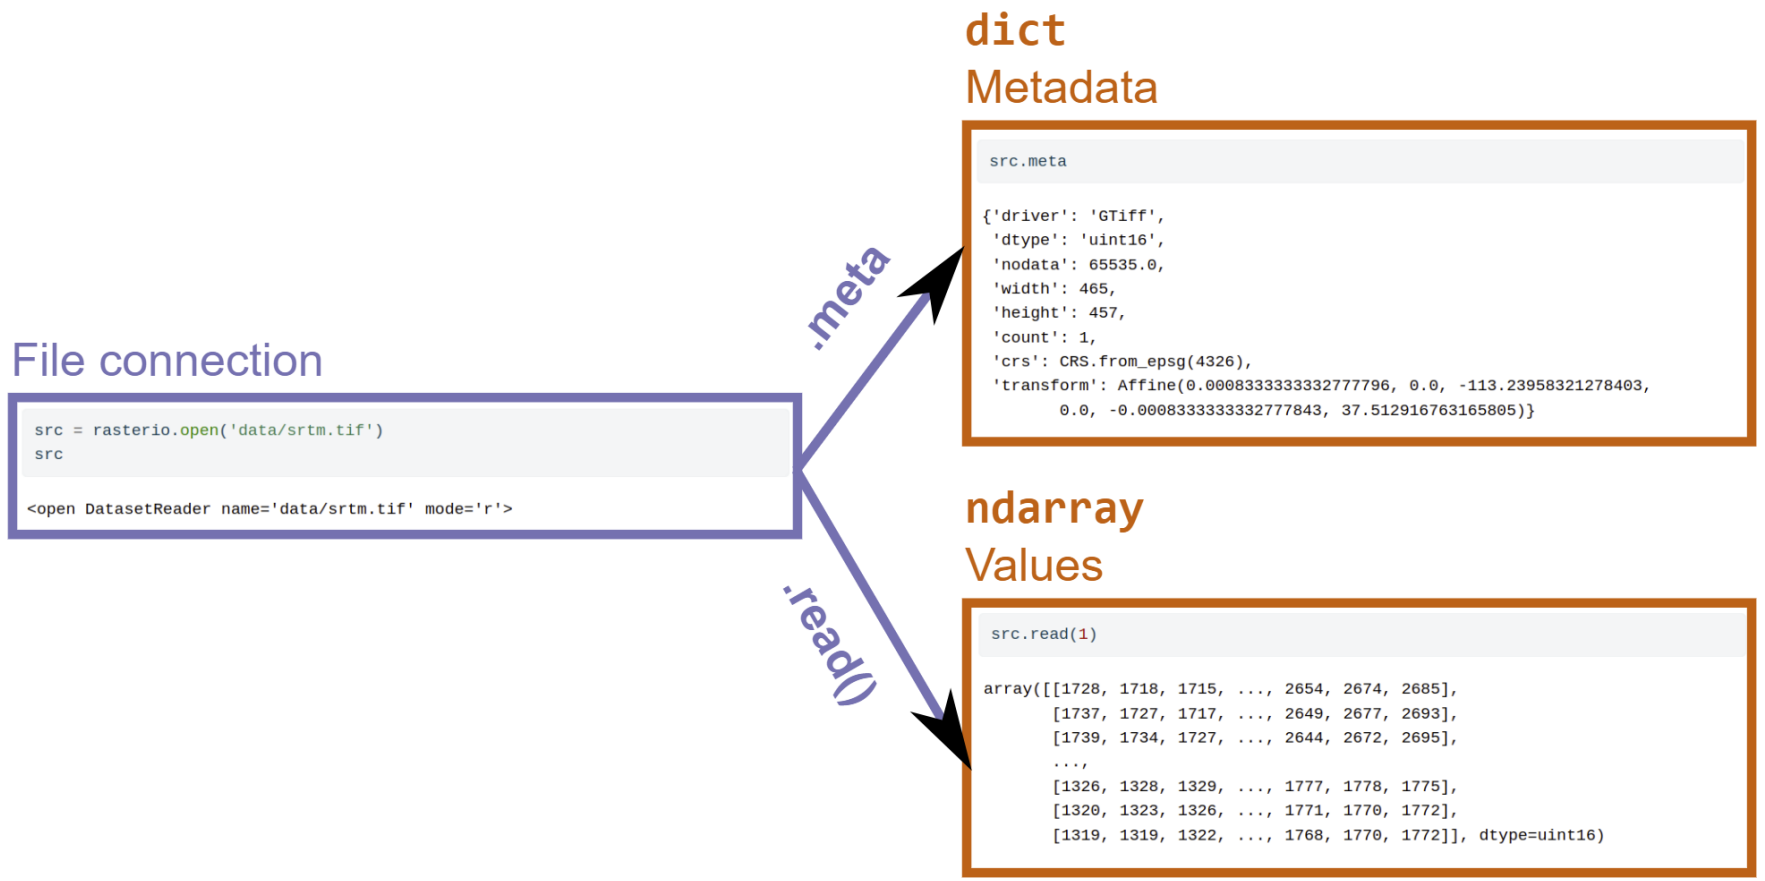




Библиотека Xarray
https://docs.xarray.dev/en/stable/

xarray

Rasterio: растровые геоданные

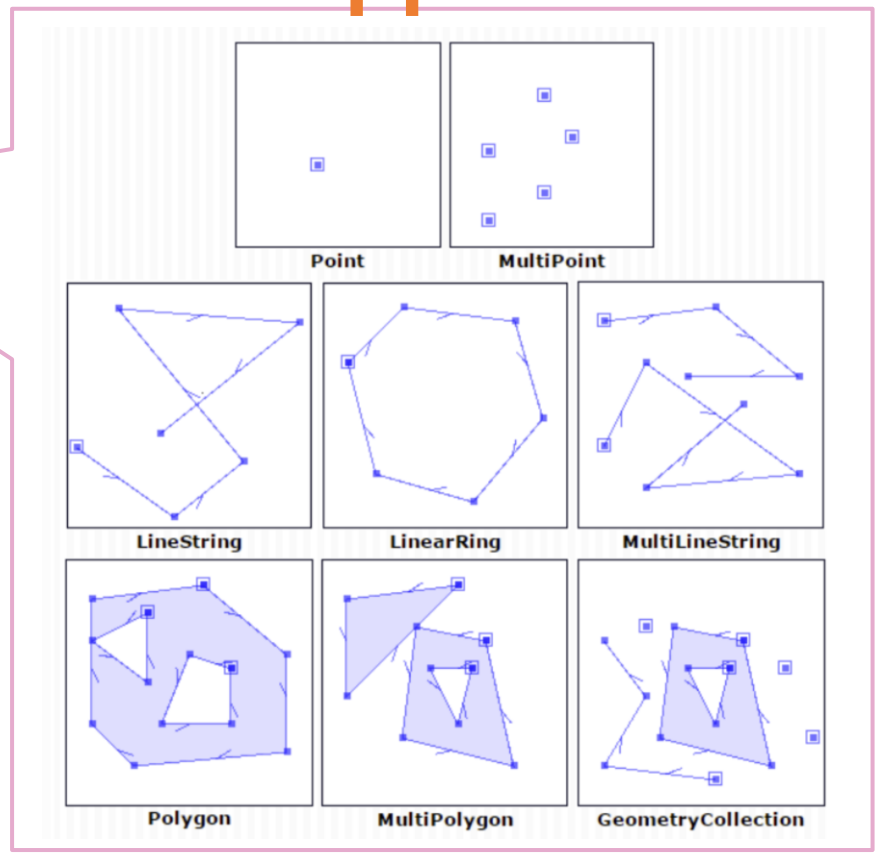


Rasterio

https://rasterio.readthedocs.io/en/stable/#

Shapely + GPD: векторные геоданные

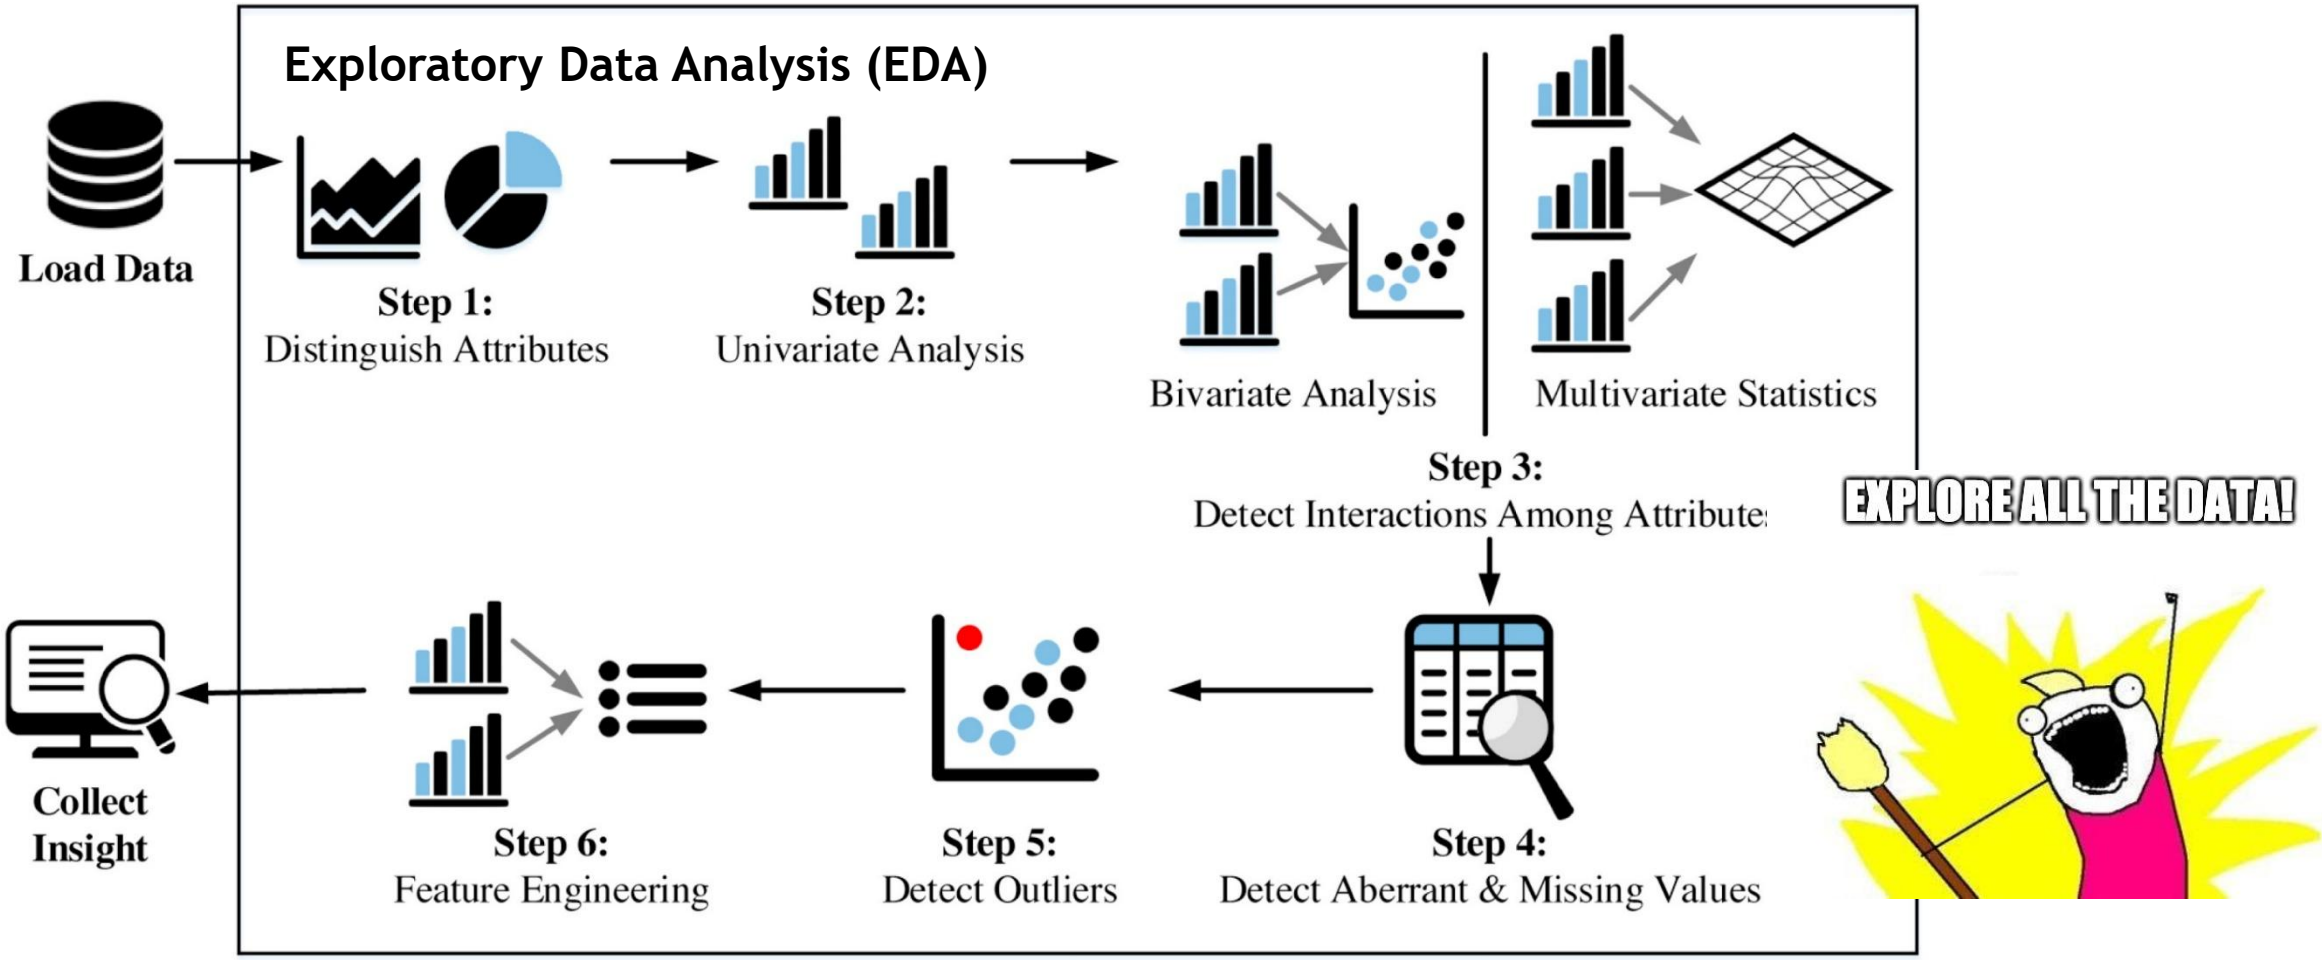




Shapely + pandas = GeoPandas

https://geopandas.org/en/stable/

Разведочный анализ данных (EDA)

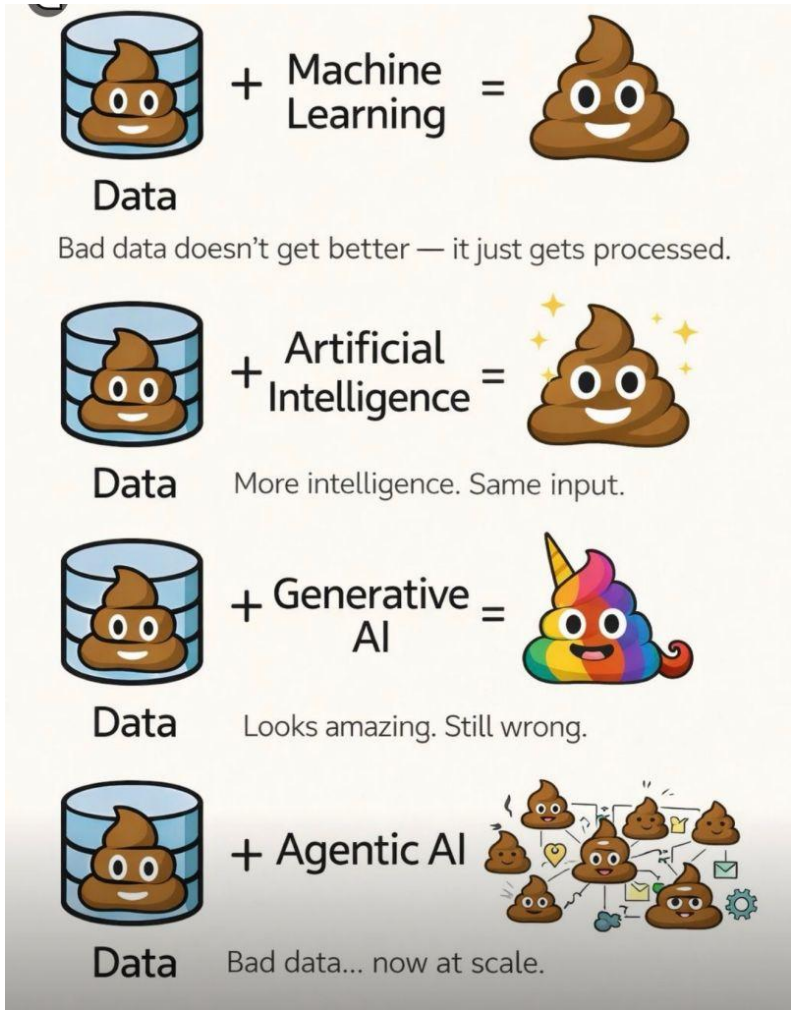


Ghosh et al. (2018). A comprehensive review of tools for exploratory analysis of tabular industrial datasets. Visual Informatics 2, 235–253. https://doi.org/10.1016/j.visinf.2018.12.004

Разведочный анализ данных (EDA)

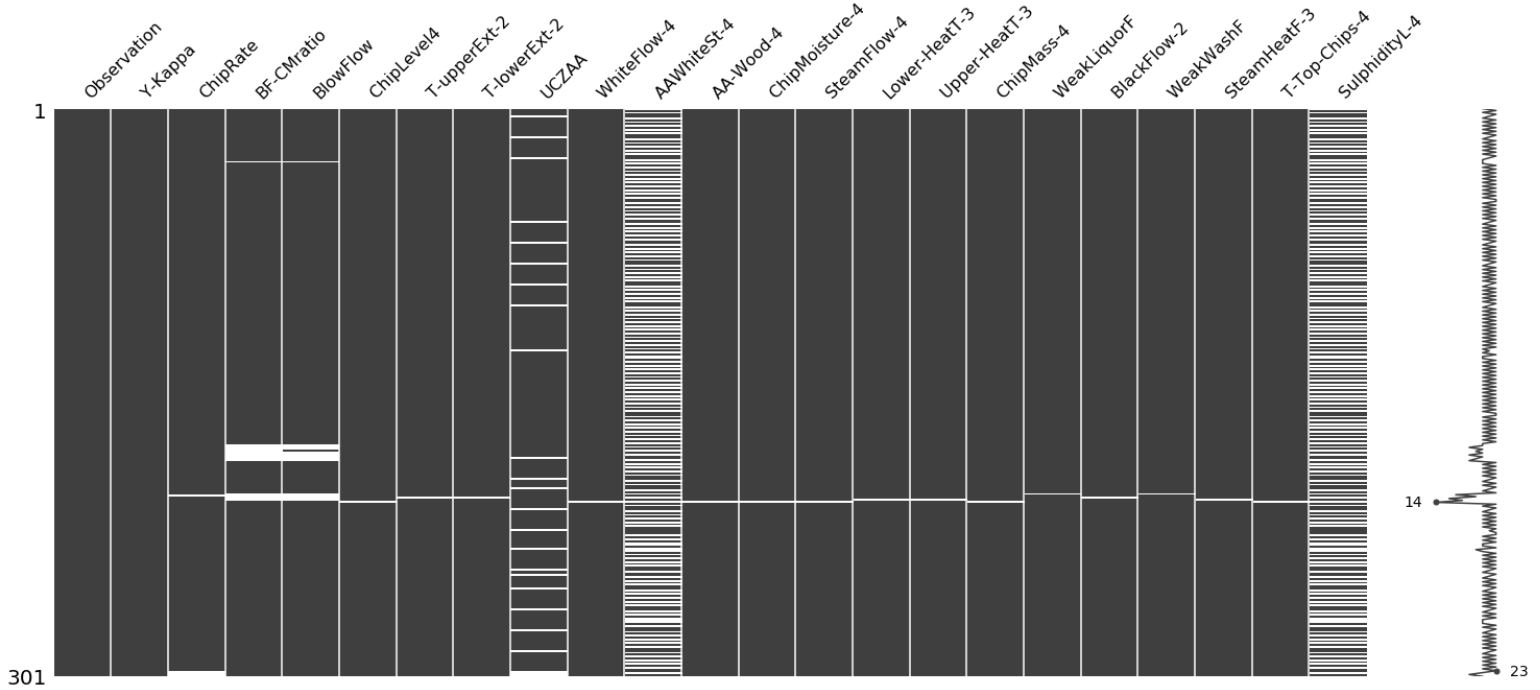


GIGO



EDA в гидрометеорологии

- Пропуски в данных разной природы (если речь про наблюдения)
- Цикличность (сезоны, сутки, колебания климата)
- Автокорреляция по времени и пространству
- Нестационарность (изменение климата)



EDA в гидрометеорологии

Перейдем к практике